

Dans ce sujet, par convention un vecteur x est un vecteur colonne. On notera x^T la transposée du vecteur (ou de la matrice) x .

Exercice 1. Soit $1 \leq p \leq n - 2$ deux entiers naturels, et A une matrice de taille $n \times p$ de rang p , connue. Soit (Y_1, \dots, Y_n) une observation du modèle statistique :

$$(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \{\mathbb{P}_\theta = p_\theta \cdot \text{Leb}^{\otimes n} : \theta = (\beta, \sigma^2) \in \Theta := \mathbb{R}^p \times \mathbb{R}_+^*\})$$

où $\text{Leb}^{\otimes n}$ est la mesure de Lebesgue sur \mathbb{R}^n et p_θ est une densité par rapport à $\text{Leb}^{\otimes n}$ donnée par :

$$p_\theta(\mathbf{y}) := \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2}\|\mathbf{y} - A\beta\|^2\right); \quad \theta = (\beta, \sigma^2) \in \Theta, \quad \mathbf{y} := \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} \in \mathbb{R}^n$$

Nous notons

$$\mathbf{Y} := \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} \in \mathbb{R}^n, \quad C := A^T A \in \mathbb{R}^{p \times p}, \quad H := AC^{-1}A^T \in \mathbb{R}^{n \times n}, \quad \hat{\beta} := C^{-1}A^T \mathbf{Y} \in \mathbb{R}^p.$$

Nous rappelons que

- H est le projecteur orthogonal sur $\text{Im}(A)$, le sous-espace vectoriel de \mathbb{R}^n engendré par les colonnes de la matrice A .
- $\hat{\beta}$ est l'estimateur des moindres carrés, i.e. l'unique minimum de

$$\beta \mapsto J(\beta) := \|\mathbf{Y} - A\beta\|^2.$$

Nous considérons maintenant un modèle dans lequel nous ajoutons un régresseur (i.e. “une variable explicative”) $\mathbf{z} \in \mathbb{R}^{n \times 1}$ vérifiant $(I - H)\mathbf{z} \neq \mathbf{0}_{n \times 1}$. Nous supposons maintenant que (Y_1, \dots, Y_n) est une observation du modèle statistique

$$(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \{\mathbb{Q}_{\bar{\theta}} = q_{\bar{\theta}} \cdot \text{Leb}^{\otimes n} : \bar{\theta} = (\bar{\beta}, \gamma, \bar{\sigma}^2) \in \bar{\Theta} := \mathbb{R}^p \times \mathbb{R} \times \mathbb{R}_+^*\})$$

où $q_{\bar{\theta}}$ est une densité par rapport à la mesure de Lebesgue sur \mathbb{R}^n donnée par :

$$q_{\bar{\theta}}(\mathbf{y}) := \frac{1}{(2\pi\bar{\sigma}^2)^{n/2}} \exp\left(-\frac{1}{2\bar{\sigma}^2}\|\mathbf{y} - A\bar{\beta} - \mathbf{z}\gamma\|^2\right); \quad \bar{\theta} = (\bar{\beta}, \gamma, \bar{\sigma}^2) \in \bar{\Theta}.$$

Nous posons

$$\mathbf{z}_\perp := (I - H)\mathbf{z}, \quad V := [A, \mathbf{z}_\perp], \quad \mathbf{k}_z := C^{-1}A^T \mathbf{z}.$$

Remarquons que

$$A^T \mathbf{z}_\perp = \mathbf{0}_{p \times 1} \quad \text{et} \quad \mathbf{z} = A\mathbf{k}_z + \mathbf{z}_\perp.$$

1. Montrer que, pour tout $\bar{\theta} = (\bar{\beta}, \gamma, \bar{\sigma}^2) \in \bar{\Theta}$,

$$\mathbb{E}_{\bar{\theta}}[\mathbf{Y}] = V \begin{bmatrix} \bar{\beta} + \mathbf{k}_z \gamma \\ \gamma \end{bmatrix}.$$

2. Montrer que l'estimateur $\hat{\lambda}$ des moindres carrés de λ défini par

$$\hat{\lambda} = \arg \min_{\lambda \in \mathbb{R}^{p+1}} \|\mathbf{Y} - V\lambda\|^2$$

est donné par

$$\hat{\lambda} := \begin{bmatrix} C^{-1}A^T\mathbf{Y} \\ \|\mathbf{z}_\perp\|^{-2}\mathbf{z}_\perp^T\mathbf{Y} \end{bmatrix}.$$

3. Déterminer l'estimateur $(\hat{\beta}, \hat{\gamma})$ des moindres carrés de $(\bar{\beta}, \gamma)$, défini par

$$(\hat{\beta}, \hat{\gamma}) = \arg \min_{(\beta, \gamma) \in \mathbb{R}^p \times \mathbb{R}} \|\mathbf{Y} - A\bar{\beta} - \mathbf{z}\gamma\|^2$$

en fonction de $\hat{\lambda}$.

4. Déterminer la distribution de l'estimateur $\hat{\gamma}$ sous $\mathbb{Q}_{\bar{\theta}}$ pour $\bar{\theta} = (\bar{\beta}, \gamma, \bar{\sigma}^2) \in \bar{\Theta}$.
 5. Montrer que le projecteur orthogonal \bar{H} sur $\text{Im}(V)$ est donné par

$$\bar{H} := H + \|\mathbf{z}_\perp\|^{-2}\mathbf{z}_\perp\mathbf{z}_\perp^T.$$

6. En déduire un estimateur $\hat{\sigma}^2$ sans biais de $\bar{\sigma}^2$ [exprimer $\hat{\sigma}^2$ en fonction de $\hat{\sigma}^2$ et $\mathbf{z}_\perp^T\mathbf{Y}$].
 7. Déterminer la distribution de $(n-p-1)\hat{\sigma}^2/\bar{\sigma}^2$ sous $\mathbb{Q}_{\bar{\theta}}$ pour $\bar{\theta} = (\bar{\beta}, \gamma, \bar{\sigma}^2) \in \bar{\Theta}$.
 8. Construire un test $H_0 : \gamma = 0$, contre $H_1 : \gamma \neq 0$ de niveau $\alpha \in]0, 1[$.

Exercice 2. Soit $n \geq 3$ et $Z = (X_1, \dots, X_n)$ un n -échantillon du modèle

$$(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+), \{p_\theta \cdot \text{Leb}, \theta \in \mathbb{R}_+^*\}),$$

où Leb est la mesure de Lebesgue sur \mathbb{R} et p_θ est définie par

$$x \mapsto p_\theta(x) := \theta x^{\theta-1} \mathbb{1}_{]0,1[}(x) = \theta e^{(\theta-1)\log(x)} \mathbb{1}_{]0,1[}(x).$$

Nous admettons que le modèle statistique est régulier.

- Déterminer l'estimateur du maximum de vraisemblance $\hat{\theta}_n$ du paramètre θ .
- Déterminer la distribution asymptotique de la suite d'estimateurs $\sqrt{n}(\hat{\theta}_n - \theta)$.
- Montrer que sous $p_\theta \cdot \text{Leb}$, la loi de la variable $Y_1 := -\log(X_1)$ est Gamma(1, θ) (voir Définition IV-5.12 dans le polycopié). En déduire la loi, sous $p_\theta \cdot \mu$, de $\sum_{i=1}^n Y_i$ où $Y_i := -\log(X_i)$.
- Calculer pour tout $\theta \in \mathbb{R}_+^*$, $\mathbb{E}_\theta[\hat{\theta}_n]$ et $\text{Var}_\theta(\hat{\theta}_n)$.
- Montrer qu'il existe une suite réelle (déterministe) $\{a_n, n \in \mathbb{N}\}$ telle que $\tilde{\theta}_n := a_n \hat{\theta}_n$ soit un estimateur sans biais de θ .
- L'estimateur $\tilde{\theta}_n$ est-il efficace ?
- Montrer que $n\theta/\hat{\theta}_n$ est une fonction pivotale pour le paramètre θ dont on déterminera la distribution. En déduire un intervalle de confiance exact de niveau $1 - \alpha$ pour $\alpha \in]0, 1[$.

Exercice 3. Soit $Z = (X_1, \dots, X_n)$ un n -échantillon du modèle

$$(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+), \{p_\theta \cdot \text{Leb}, \theta = (\mu, \rho) \in \Theta := \mathbb{R} \times \mathbb{R}_+^*\}),$$

où Leb est la mesure de Lebesgue sur \mathbb{R} et p_θ est définie par

$$x \mapsto p_\theta(x) := \frac{1}{\rho} \mathbb{1}_{[\mu-\rho/2, \mu+\rho/2]}(x), \quad \theta = (\mu, \rho) \in \Theta.$$

Dans la suite nous supposons que $n \geq 3$. Nous notons $X_{n:1} := \min(X_1, \dots, X_n)$, $X_{n:n} := \max(X_1, \dots, X_n)$ et $R_n := X_{n:n} - X_{n:1}$ et pour $\theta = (\mu, \rho) \in \Theta$,

$$A_\theta := \{(u, v) \in \mathbb{R}^2 : \mu - \rho/2 \leq u \leq v \leq \mu + \rho/2\}.$$

1. Déterminer un estimateur de maximum de vraisemblance de (μ, ρ) . Cet estimateur est-il unique ?
2. Soit $\theta = (\mu, \rho) \in \Theta$. Montrer que sous $\mathbb{P}_{n,\theta}$, la loi jointe de $(X_{n:1}, X_{n:n})$ a une densité par rapport à la mesure de Lebesgue sur \mathbb{R}^2 donnée par

$$(u, v) \mapsto f_{n,\theta}(u, v) := \frac{n(n-1)}{\rho^n} (v-u)^{n-2} \mathbb{1}_{A_\theta}(u, v).$$

3. Soit $\theta = (\mu, \rho) \in \Theta$. Montrer que sous $\mathbb{P}_{n,\theta}$, la loi de R_n a une densité par rapport à la mesure de Lebesgue sur \mathbb{R} donnée par

$$r \mapsto g_{n,\theta}(r) := \frac{n(n-1)}{\rho^n} r^{n-2} (\rho-r) \mathbb{1}_{[0,\rho]}(r).$$

4. Soit $\theta = (\mu, \rho) \in \Theta$. Montrer que la suite $n(\rho - R_n)$ converge en loi sous $\mathbb{P}_{n,\theta}$ et identifier la loi limite.

Exercice 4. Dans la suite, toutes les variables sont définies sur le même espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$.

On considère un problème de classification binaire. Nous étudions la situation où les données d'apprentissage sont affectées d'erreurs sur les labels. Pour formaliser cette situation, nous supposons disposer d'un ensemble d'apprentissage $\{(X_i, Z_i)\}_{i=1}^n$, où n est le nombre d'exemples, $\{(X_i, Z_i)\}_{i=1}^n$ est une suite de variables aléatoires i.i.d. de même loi que (X, Z) . Nous notons (X, Y) le couple "attribut" "label", avec $Y \in \{0, 1\}$ et notons Z , le label bruité

$$Z := \begin{cases} Y & \text{si } B = 0, \\ 1 - Y & \text{si } B = 1, \end{cases}$$

où B est une variable de Bernoulli de paramètre $p \in [0, 1/2[$ indépendante de (X, Y) .

Nous notons \mathcal{C} un ensemble de règles de classification que nous supposons de cardinal $|\mathcal{C}|$ fini. Pour tout $g \in \mathcal{C}$, nous définissons

- le risque de classification sur les observations sans bruit : $R(g) := \mathbb{P}(g(X) \neq Y)$,
- le risque de classification sur les observations bruitées : $R^b(g) := \mathbb{P}(g(X) \neq Z)$,
- le risque empirique sur les observations bruitées : $R_n^b(g) := \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{g(X_i) \neq Z_i\}}$.
- g^* une règle de classification minimisant le risque de classification sans bruit : $g^* \in \arg \min_{g \in \mathcal{C}} R(g)$

- \hat{g}_n^* une règle de classification minimisant le risque empirique sur les observations bruitées :
 $\hat{g}_n^* \in \arg \min_{g \in \mathcal{C}} R_n^b(g)$
- R^* le minimum du risque de classification : $R^* := \inf_{g \in \mathcal{C}} R(g) = R(g^*)$.

Soit $\varepsilon > 0$ et $\delta \in]0, 1[$, fixés dans toute la suite. Nous allons démontrer que la suite de règles de classification \hat{g}_n^* est (ε, δ) -PAC, i.e. il existe un entier $n(\varepsilon, \delta)$ (que nous déterminerons) tel que

$$\forall n \geq n(\varepsilon, \delta), \quad \mathbb{P}(R(\hat{g}_n^*) - R^* > \varepsilon) \leq \delta. \quad (1)$$

Posons $\bar{\varepsilon} := \varepsilon(1 - 2p)$.

1. Montrer que pour tout $g \in \mathcal{C}$,

$$R^b(g) = p + R(g)(1 - 2p).$$

En déduire une relation entre $R^b(g) - R^b(g^*)$ et $R(g) - R(g^*)$ pour tout classifieur $g \in \mathcal{C}$.

2. Montrer qu'il existe $n_0(\varepsilon, \delta)$ (que l'on déterminera) tel que pour tout $n \geq n_0(\varepsilon, \delta)$,

$$\mathbb{P}\left(R_n^b(g^*) - R^b(g^*) \leq \bar{\varepsilon}/2\right) \geq 1 - \delta/2.$$

3. Montrer qu'il existe $n_1(\varepsilon, \delta)$ (que l'on déterminera) tel que pour tout $n \geq n_1(\varepsilon, \delta)$,

$$\mathbb{P}\left(\sup_{g \in \mathcal{C}} \{R^b(g) - R_n^b(g)\} \leq \bar{\varepsilon}/2\right) \geq 1 - \delta/2.$$

4. Etablir (1) [déterminer $n(\varepsilon, \delta)$].
5. De combien doit augmenter le nombre de données pour avoir la même garantie entre $p = 0$ et $p = 0,05$?

1 Solutions

Solution 1. 1. Nous avons

$$\mathbb{E}_{\bar{\beta}, \gamma, \bar{\sigma}^2}[\mathbf{Y}] = A\bar{\beta} + \mathbf{z}\gamma = A(\bar{\beta} + \mathbf{k}_z\gamma) + \mathbf{z}_\perp\gamma.$$

2. L'estimateur des moindres carrés de λ est donné par

$$\hat{\lambda} = (V^T V)^{-1} V^T \mathbf{Y} = \begin{bmatrix} A^T A & 0 \\ 0 & \|\mathbf{z}_\perp\|^2 \end{bmatrix}^{-1} \begin{bmatrix} A^T \mathbf{Y} \\ \mathbf{z}_\perp^T \mathbf{Y} \end{bmatrix} = \begin{bmatrix} C^{-1} A^T \mathbf{Y} \\ \|\mathbf{z}^T\|^{-2} \mathbf{z}_\perp^T \mathbf{Y} \end{bmatrix}$$

3. Nous posons $\hat{\alpha} = C^{-1} A^T \mathbf{Y}$, $\hat{\gamma} = \|\mathbf{z}^T\|^{-2} \mathbf{z}_\perp^T \mathbf{Y}$ et $\hat{\beta} = \hat{\alpha} - \mathbf{k}_z \hat{\gamma}$. Nous allons montrer que $(\hat{\beta}, \hat{\gamma})$ est l'estimateur des moindres carrés de $(\bar{\beta}, \gamma)$. En effet : pour tout $\lambda \in \mathbb{R}^{p+1}$, nous avons

$$\|\mathbf{Y} - A\hat{\beta} - \mathbf{z}\hat{\gamma}\|^2 = \|\mathbf{Y} - A\hat{\alpha} + A\mathbf{k}_z\hat{\gamma} - \mathbf{z}\hat{\gamma}\|^2 = \|\mathbf{Y} - A\hat{\alpha} - \mathbf{z}_\perp\hat{\gamma}\|^2 \leq \|\mathbf{Y} - V\lambda\|^2$$

Et donc, pour tout $(\bar{\beta}, \gamma) \in \mathbb{R}^p \times \mathbb{R}$, en posant

$$\lambda = \begin{bmatrix} \bar{\beta} + A\mathbf{k}_z\gamma \\ \gamma \end{bmatrix}$$

nous avons

$$\|\mathbf{Y} - A\hat{\beta} - \mathbf{z}\hat{\gamma}\|^2 \leq \|\mathbf{Y} - A\bar{\beta} - \mathbf{z}\gamma\|^2$$

4. \mathbf{Y} est un vecteur gaussien $n \times 1$ de moyenne $A\bar{\beta} + \mathbf{z}\gamma$ et de covariance $\sigma^2 \mathbf{I}$. Donc, $\mathbf{z}_\perp^T \mathbf{Y} / \|\mathbf{z}_\perp\|^2$ est une variable gaussienne de moyenne γ (car $\mathbf{z}_\perp^T A = 0$ et $\mathbf{z}_\perp^T \mathbf{z} = \|\mathbf{z}_\perp\|^2$) et de variance $\sigma^2 \|\mathbf{z}_\perp\|^{-2}$.
5. $\text{Im}(V) = \text{Im}(A) \perp \text{Vect}(\mathbf{z}_\perp)$ où \perp est la somme directe orthogonale et $\text{Vect}(\mathbf{z}_\perp)$ est l'espace vectoriel engendré par \mathbf{z}_\perp . Par conséquent, $\bar{\mathbf{H}}$ est la somme du projecteur orthogonal sur $\text{Im}(A)$ et du projecteur orthogonal sur \mathbf{z}_\perp .
6. $\hat{\sigma}^2 = (n - p - 1)^{-1} \{\|\mathbf{Y}\|^2 - \|\bar{\mathbf{H}}\mathbf{Y}\|^2\}$ est un estimateur sans biais de σ^2 . Comme

$$\|\bar{\mathbf{H}}\mathbf{Y}\|^2 = \|\mathbf{H}\mathbf{Y}\|^2 + \frac{(\mathbf{z}_\perp^T \mathbf{Y})^2}{\|\mathbf{z}_\perp\|^2}$$

nous en déduisons que

$$\hat{\sigma}^2 = \frac{n - p}{n - p - 1} \hat{\sigma}^2 - \frac{1}{n - p - 1} \frac{(\mathbf{z}_\perp^T \mathbf{Y})^2}{\|\mathbf{z}_\perp\|^2}.$$

7. Comme $\sigma^{-1} \{\mathbf{Y} - (A\bar{\beta} - \mathbf{z}\gamma)\}$ est sous $\mathbb{Q}_{\bar{\beta}, \gamma, \bar{\sigma}^2}$ un vecteur gaussien centré de covariance identité,

$$(n - p - 1) \hat{\sigma}^2 / \sigma^2$$

est distribué suivant une loi du *chi*² à $(n - p - 1)$ degrés de liberté. Par le théorème de Cochran, les vecteurs $\bar{\mathbf{H}}\mathbf{Y}$ et $(\mathbf{I} - \bar{\mathbf{H}})\mathbf{Y}$ sont indépendants sous $\mathbb{Q}_{\bar{\beta}, \gamma, \bar{\sigma}^2}$. L'indépendance de $\hat{\sigma}^2$ et $\hat{\gamma}$ en découle car $\hat{\sigma}^2$ est une fonction de $(\mathbf{I} - \bar{\mathbf{H}})\mathbf{Y}$ et $\hat{\gamma}$ de $\bar{\mathbf{H}}\mathbf{Y}$.

8. Il découle de la question précédente que $\mathbb{Q}_{\hat{\beta}, \gamma, \hat{\sigma}^2}$,

$$T_n(\mathbf{Y}) = \frac{\sqrt{n} \|\mathbf{z}_\perp\| (\hat{\gamma} - \gamma)}{\hat{\sigma}}$$

est une loi de Student à $n - p - 1$ -degrés de liberté. En notant pour $b \in [0, 1[$, t_b^{n-p-1} le quantile d'ordre b de la loi de Student, le test de

$$\delta_n(\mathbf{Y}) = \mathbb{1}_{\left[t_{1-a/2}^{n-p-1}, \infty\right[}(|T_n(\mathbf{Y})|)$$

est un test de niveau a .

Solution . 1. Sous \mathbb{P}_θ , les v.a. $(X_i)_i$ sont indépendantes et de densité p_θ donc la vraisemblance est donnée par

$$\theta \mapsto \theta^n \exp \left((\theta - 1) \sum_{i=1}^n \log X_i \right) \prod_{i=1}^n \mathbb{1}_{X_i \in]0, 1[}.$$

Pour $Z \in]0, 1[^n$, la log-vraisemblance normalisée est

$$\theta \mapsto \log \theta + (\theta - 1) \frac{1}{n} \sum_{i=1}^n \log X_i.$$

Il s'agit d'une fonction de classe C^1 sur \mathbb{R}_+^* dont la dérivée vaut $\theta^{-1} + \frac{1}{n} \sum_{i=1}^n \log X_i$ et s'annule en

$$\theta_{n,*} := - \frac{1}{\frac{1}{n} \sum_{i=1}^n \log X_i}.$$

De plus, on peut vérifier que la dérivée est positive sur $]0, \theta_{n,*}]$ et négative sur $[\theta_{n,*}, +\infty[$. Ce point est donc bien un maximum de la fonction vraisemblance. Ainsi $\hat{\theta}_n = \theta_{n,*}$.

2. **Réponse 1.** Utiliser le cours pour donner la loi asymptotique du maximum de vraisemblance dans un modèle régulier.

Réponse 2. L'estimateur est de la forme $(\frac{1}{n} \sum_{i=1}^n U_i)^{-1}$ où $U_i := -\log X_i$. Le TCL pour des v.a. i.i.d. possédant un moment d'ordre 2 donne

$$\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n U_i - \mathbb{E}_{n,\theta} [U_i] \right) \xrightarrow{\mathbb{P}_{n,\theta}} \mathcal{N}(0, \text{Var}_{n,\theta}(U_1)).$$

Puis nous appliquons la méthode δ avec la fonction $g : u \mapsto 1/u$, qui est de classe C^1 sur \mathbb{R}^+ et inversible. Il vient

$$\sqrt{n} \left(g \left(\frac{1}{n} \sum_{i=1}^n U_i \right) - g(\mathbb{E}_{n,\theta} [U_i]) \right) \xrightarrow{\mathbb{P}_{n,\theta}} g'(\mathbb{E}_{n,\theta} [U_i]) \mathcal{N}(0, \text{Var}_{n,\theta}(U_1)) \equiv \mathcal{N}(0, (\mathbb{E}_{n,\theta} [U_i])^{-4} \text{Var}_{n,\theta}(U_1)).$$

Ici, sous $\mathbb{P}_{n,\theta}$, U_i suit une Gamma de paramètres $(1, \theta)$ (voir question suivante). Son espérance est $1/\theta$ et sa variance est $1/\theta^2$. On en déduit que

$$\sqrt{n} (\hat{\theta}_n - \theta) \xrightarrow{\mathbb{P}_{n,\theta}} \mathcal{N}(0, \theta^2).$$

3. Soit h une fonction mesurable positive. Nous avons, en utilisant que le changement de variable $y = -\log x$ est bijectif de $]0, 1[$ dans \mathbb{R}_+^* ,

$$\begin{aligned}\mathbb{E}_\theta [h(Y_1)] &= \mathbb{E}_\theta [h(-\log X_1)] = \theta \int_0^1 h(-\log x) x^{\theta-1} dx \\ &= \theta \int_0^{+\infty} h(y) \exp(-(\theta-1)y) \exp(-y) dy = \theta \int_0^{+\infty} h(y) \exp(-\theta y) dy.\end{aligned}$$

On reconnaît la densité d'une loi Gamma de paramètres $(1, \theta)$. Sous \mathbb{P}_θ , les v.a. $(X_i)_i$ sont i.i.d. donc il en est de même pour les v.a. $(Y_i)_i$. En utilisant un résultat sur la somme de lois Gamma indépendantes de premier paramètre identique (voir Lemme IV-5.13), il vient $\sum_{i=1}^n Y_i$ suit une loi Gamma de paramètres (n, θ) .

4. Soit $\theta > 0$. Nous avons, en utilisant le résultat de la question précédente,

$$\begin{aligned}\mathbb{E}_\theta [\hat{\theta}_n] &= \mathbb{E}_\theta \left[\frac{1}{\frac{1}{n} \sum_{i=1}^n (-\log X_i)} \right] = \frac{\theta^n}{\Gamma(n)} \int_0^\infty \frac{n}{s} s^{n-1} \exp(-\theta s) ds \\ &= \frac{n\theta^n}{\Gamma(n)} \int_0^\infty s^{n-2} \exp(-\theta s) ds = \frac{n\theta^n \Gamma(n-1)}{\Gamma(n)\theta^{n-1}} \frac{\theta^{n-1}}{\Gamma(n-1)} \int_0^\infty s^{n-2} \exp(-\theta s) ds \\ &= \frac{n\Gamma(n-1)}{\Gamma(n)} \theta = \frac{n}{n-1} \theta.\end{aligned}$$

Dans la dernière ligne, on a observé que l'on intégrait la densité d'une loi Gamma de paramètres $(n-1, \theta)$; et utilisé que pour un entier $n > 0$, $\Gamma(n) = (n-1)!$.

Calculons le moment d'ordre 2. Il vient

$$\begin{aligned}\mathbb{E}_\theta [\hat{\theta}_n^2] &= \mathbb{E}_\theta \left[\frac{1}{\frac{1}{n^2} (\sum_{i=1}^n (-\log X_i))^2} \right] = \frac{\theta^n}{\Gamma(n)} \int_0^\infty \frac{n^2}{s^2} s^{n-1} \exp(-\theta s) ds \\ &= \frac{n^2 \theta^n}{\Gamma(n)} \int_0^\infty s^{n-3} \exp(-\theta s) ds = \frac{n^2 \theta^n \Gamma(n-2)}{\Gamma(n)\theta^{n-2}} \frac{\theta^{n-2}}{\Gamma(n-2)} \int_0^\infty s^{n-3} \exp(-\theta s) ds \\ &= \frac{n^2 \Gamma(n-2)}{\Gamma(n)} \theta^2 = \frac{n^2}{(n-1)(n-2)} \theta^2.\end{aligned}$$

On en déduit que la variance vaut

$$\text{Var}_\theta(\hat{\theta}_n) = \frac{n^2}{(n-1)(n-2)} \theta^2 - \left(\frac{n}{n-1} \theta \right)^2 = \frac{n^2}{(n-1)} \theta^2 \left(\frac{1}{n-2} - \frac{1}{n-1} \right) = \frac{n^2}{(n-1)^2(n-2)} \theta^2.$$

5. Nous cherchons a_n tel que pour tout $\theta > 0$, $\mathbb{E}_\theta [\tilde{\theta}_n] = \theta$. D'après la question précédente, il faut prendre

$$a_n := \frac{n-1}{n}.$$

6. Il faut comparer l'erreur quadratique de l'estimateur à la borne de Cramer-Rao. Comme l'estimateur est sans biais, sa variance et son erreur quadratique coïncident. Nous avons donc

$$\mathbb{E}_\theta [(\tilde{\theta}_n - \theta)^2] = a_n^2 \text{Var}_\theta(\hat{\theta}_n) = \frac{\theta^2}{n-2}.$$

Par ailleurs, la borne de Cramer-Rao est donnée par $(nI(\theta))^{-1}$ où $I(\theta)$ désigne l'information de Fisher associée à une seule observation :

$$I(\theta) := \mathbb{E}_\theta \left[(\partial_\theta \log p_\theta(X_1))^2 \right];$$

cette quantité est indépendante de n . Nous avons donc une dépendance en la taille n de l'échantillon qui ne coïncide pas ; l'estimateur sans biais n'est pas efficace.

7. Montrons que pour tout $\theta > 0$, la loi de $n\theta/\hat{\theta}_n$ sous \mathbb{P}_θ ne dépend pas de θ , et identifions cette loi. Soit h une fonction mesurable positive ; il vient, en utilisant l'expression de $\hat{\theta}_n$ et la question 3,

$$\begin{aligned} \mathbb{E}_\theta \left[h \left(\frac{n\theta}{\hat{\theta}_n} \right) \right] &= \mathbb{E}_\theta \left[h \left(\theta \sum_{i=1}^n (-\log X_i) \right) \right] \\ &= \frac{\theta^n}{\Gamma(n)} \int_0^\infty h(\theta s) s^{n-1} \exp(-\theta s) ds = \frac{1}{\Gamma(n)} \int_0^\infty h(w) w^{n-1} \exp(-w) dw. \end{aligned}$$

On reconnaît la loi Gamma de paramètres $(n, 1)$.

Notons $q_{n,\tau}$ les quantiles d'une loi Gamma de paramètres $(n, 1)$. Nous avons donc pour tout $\theta > 0$,

$$\mathbb{P}_\theta \left(q_{n,\alpha/2} \leq \frac{n\theta}{\hat{\theta}_n} \leq q_{n,1-\alpha/2} \right) = 1 - \alpha.$$

Ce qui permet de proposer un intervalle de confiance *exact* de la forme

$$\left[\hat{\theta}_n \frac{q_{n,\alpha/2}}{n}, \hat{\theta}_n \frac{q_{n,1-\alpha/2}}{n} \right].$$

Solution . 1. La vraisemblance du n -échantillon Z est

$$\theta \mapsto \frac{1}{\rho^n} \prod_{i=1}^n \mathbb{1}_{[\mu-\rho/2, \mu+\rho/2]}(X_i) = \frac{1}{\rho^n} \mathbb{1}_{A_\theta}(X_{n:1}, X_{n:n}).$$

En particulier, $\mathbb{1}_{A_\theta}(X_{n:1}, X_{n:n}) = 1$ pour tout $\theta = (\mu, \rho) \in \mathbb{R} \times \mathbb{R}_+^*$ vérifiant

$$\rho = \mu + \rho/2 - (\mu - \rho/2) \geq X_{n:n} - X_{n:1}$$

et la vraisemblance est donc maximisé par la plus petite valeur de ρ satisfaisant cette contrainte. Nous avons donc $\hat{\rho}_n = X_{n:n} - X_{n:1}$. Cette valeur de $\hat{\rho}_n$ étant choisie, $\mathbb{1}_{A_{\mu, \hat{\rho}_n}}(X_{n:1}, X_{n:n}) = 1$ pour tout $\mu \in \mathbb{R}$ vérifiant

$$\mu - \hat{\rho}_n/2 \leq X_{n:1} \leq X_{n:n} \leq \mu + \hat{\rho}_n/2 \implies \mu \leq (1/2)(X_{n:1} + X_{n:n}) \leq \mu.$$

L'estimateur du maximum de vraisemblance est unique et donné par

$$\hat{\mu}_n = \frac{X_{n:1} + X_{n:n}}{2}, \quad \hat{\rho}_n = X_{n:n} - X_{n:1}.$$

2. Soient $s \leq t$. Nous avons, par indépendance des v.a. puis leur loi identique,

$$\mathbb{P}_{n,\theta} \left(s \leq \min_i X_i \leq \max_i X_i \leq t \right) = \prod_{i=1}^n \mathbb{P}_{n,\theta}(s \leq X_i \leq t) = (\mathbb{P}_{n,\theta}(s \leq X_1 \leq t))^n.$$

En remarquant que sous \mathbb{P}_θ , X_1 suit une loi uniforme sur $[\mu - \rho/2, \mu + \rho/2]$, il vient que cette probabilité est nulle lorsque $s \geq \mu + \rho/2$ ou $t \leq \mu - \rho/2$; et sinon :

$$\mathbb{P}_{n,\theta} \left(s \leq \min_i X_i \leq \max_i X_i \leq t \right) = \rho^{-n} \{ (t \wedge (\mu + \rho/2)) - (s \vee (\mu - \rho/2)) \}^n \quad (2)$$

D'autre part, calculons pour tout $s \leq t$

$$\begin{aligned} \pi(s, t) &:= \int_{\{(x,y): s \leq x \leq y \leq t\}} f(x, y) \, dx \, dy = \int_s^t \left(\int_x^t f(x, y) \, dy \right) \, dx \\ &= \frac{n(n-1)}{\rho^n} \int_s^t \left(\int_x^t (y-x)^{n-2} \mathbb{1}_{\mu-\rho/2 \leq x \leq y \leq \mu+\rho/2}(x, y) \, dy \right) \, dx. \end{aligned}$$

Nous avons, du fait de l'indicatrice, que $\pi(s, t) = 0$ lorsque $s \geq \mu + \rho/2$ ou $t \leq \mu - \rho/2$; sinon,

$$\begin{aligned} \pi(s, t) &= \frac{n(n-1)}{\rho^n} \int_s^t \mathbb{1}_{[\mu-\rho/2, \mu+\rho/2]}(x) \left(\int_x^{t \wedge (\mu+\rho/2)} (y-x)^{n-2} \, dy \right) \, dx \\ &= \frac{n}{\rho^n} \int_{s \vee (\mu-\rho/2)}^{t \wedge (\mu+\rho/2)} (\{t \wedge (\mu + \rho/2)\} - x)^{n-1} \, dx \\ &= \rho^{-n} \{ (t \wedge (\mu + \rho/2)) - (s \vee (\mu - \rho/2)) \}^n. \end{aligned}$$

La comparaison de cette valeur de $\pi(s, t)$ et de la quantité (2) permet de démontrer l'expression de la densité proposée.

3. Soit $\theta \in \Theta$. Pour toute fonction mesurable positive h , nous avons

$$\mathbb{E}_\theta [h(R_n)] = \frac{n(n-1)}{\rho^n} \int_{A_\theta} h(y-x) (y-x)^{n-2} \, dx \, dy.$$

Nous faisons un changement de variable $(x, z) \leftarrow (x, y-x)$ qui donne, combiné au théorème de Fubini,

$$\begin{aligned} \mathbb{E}_\theta [h(R_n)] &= \frac{n(n-1)}{\rho^n} \int_{\{(x,z): \mu-\rho/2 \leq x \leq x+z \leq \mu+\rho/2\}} h(z) (z)^{n-2} \, dx \, dz \\ &= \frac{n(n-1)}{\rho^n} \int_0^\rho h(z) z^{n-2} \left(\int_{\mu-\rho/2}^{\mu+\rho/2-z} dx \right) \, dz \\ &= \frac{n(n-1)}{\rho^n} \int_0^\rho h(z) z^{n-2} (\rho - z) \, dz. \end{aligned}$$

On reconnaît l'expression de la densité donnée.

4. Remarquons que nous avons $\mathbb{P}_{n,\theta}(\rho - R_n \geq 0) = 1$ pour tout $\theta \in \Theta$; donc la limite en loi sera une v.a. positive ou nulle. Établissons la convergence en loi par un argument de convergence des fonctions de répartition. Soit $t > 0$. Nous écrivons, en utilisant la question 3,

$$\mathbb{P}_{n,\theta} (n(\rho - R_n) \leq t) = \mathbb{P}_{n,\theta} (\rho - R_n \leq t/n) = \mathbb{P}_{n,\theta} (\rho - t/n \leq R_n).$$

A t fixé, nous allons considérer la limite $n \rightarrow +\infty$; nous pouvons donc considérer que n est assez grand pour que $\rho - t/n \geq 0$. Il vient, pour une toute valeur de n assez grande ($t > 0$ fixé)

$$\begin{aligned}\mathbb{P}_{n,\theta}(n(\rho - R_n) \leq t) &= \frac{n(n-1)}{\rho^n} \int_{\rho-t/n}^{\rho} r^{n-2}(\rho - r)dr \\ &= \frac{n(n-1)}{\rho^n} \left\{ \frac{\rho}{n-1} (\rho^{n-1} - (\rho - t/n)^{n-1}) - \frac{1}{n} (\rho^n - (\rho - t/n)^n) \right\} \\ &= n \left\{ 1 - \left(1 - \frac{t}{\rho n}\right)^{n-1} \right\} - (n-1) \left\{ 1 - \left(1 - \frac{t}{\rho n}\right)^n \right\} \\ &= 1 - \left(1 - \frac{t}{\rho n}\right)^n \left\{ n \left(1 - \frac{t}{\rho n}\right)^{-1} - (n-1) \right\}\end{aligned}$$

Par conséquent, nous avons

$$\lim_{n \rightarrow \infty} \mathbb{P}_{n,\theta}(n(\rho - R_n) \leq t) = 1 - \left(1 + \frac{t}{\rho}\right) e^{-t/\rho}.$$

En dérivant par rapport à t , nous obtenons que la densité de la loi limite est donnée par

$$g(t) = \frac{t}{\rho^2} e^{-t/\rho} \mathbb{1}_{\mathbb{R}^+}(t)$$

Nous reconnaissons la densité d'une loi Gamma(2, 1/ρ).

Solution 4. 1. Notons que

$$\begin{aligned}R^b(g) &= \mathbb{P}(g(X) \neq Z) = \mathbb{P}(g(X) \neq Z, Y = Z) + \mathbb{P}(g(X) \neq Z, Y \neq Z) \\ &= \mathbb{P}(g(X) \neq Y, B = 0) + \mathbb{P}(g(X) = Y, B = 1).\end{aligned}$$

Par indépendance du couple (X, Y) et de B , nous avons

$$R^b(g) = (1 - p)R(g) + \{1 - R(g)\}p = p + (1 - 2p)R(g).$$

On en déduit que

$$R^b(g) - R^b(g^*) = (1 - 2p) (R(g) - R(g^*)).$$

2. Soit $g \in \mathcal{C}$. Nous allons démontrer que

$$\mathbb{P}\left(R_n^b(g) - R^b(g) \geq \bar{\varepsilon}/2\right) \leq \delta/2, \quad \mathbb{P}\left(R_n^b(g) - R^b(g) \leq -\bar{\varepsilon}/2\right) \leq \delta/2. \quad (3)$$

Nous écrivons

$$R_n^b(g) - R^b(g) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{g(X_i) \neq Z_i} - \mathbb{P}(g(X) \neq Z) = \frac{1}{n} \sum_{i=1}^n U_i$$

avec

$$U_i := \mathbb{1}_{g(X_i) \neq Z_i} - \mathbb{P}(g(X) \neq Z).$$

Par hypothèses, les v.a. $(U_i)_i$ sont indépendantes ; de plus, elles sont centrées, et on a

$$\mathbb{P}(-m \leq U_i \leq 1 - m) = 1 \quad m := \mathbb{P}(g(X) \neq Z) .$$

En utilisant l'inégalité de Hoeffding, nous avons puisque $b_i - a_i = 1$,

$$\mathbb{P}\left(R_n^b(g) - R^b(g) \geq \bar{\varepsilon}/2\right) \leq e^{-n\bar{\varepsilon}^2/2} ,$$

Il suffit de choisir n tel que

$$e^{-n\bar{\varepsilon}^2/2} \leq \delta/2$$

soit

$$n \geq n_0(p, \varepsilon, \delta) := \frac{2}{\bar{\varepsilon}^2} \log\left(\frac{2}{\delta}\right) .$$

On raisonne de même pour établir la seconde inégalité (en utilisant encore Hoeffding) ; et on obtient la même valeur de n_0 , qui est donc celle que l'on retient comme garantissant les deux contrôles (3).

3. Nous allons démontrer que

$$\mathbb{P}\left(\sup_{g \in \mathcal{C}} \{R^b(g) - R_n^b(g)\} \geq \bar{\varepsilon}/2\right) \leq \delta/2 .$$

Puisque \mathcal{C} est de cardinal fini, et en utilisant la question 2, nous avons

$$\begin{aligned} \mathbb{P}\left(\sup_{g \in \mathcal{C}} \{R^b(g) - R_n^b(g)\} \geq \bar{\varepsilon}/2\right) &\leq \sum_{g \in \mathcal{C}} \mathbb{P}\left(R^b(g) - R_n^b(g) \geq \bar{\varepsilon}/2\right) \\ &\leq \sum_{g \in \mathcal{C}} \mathbb{P}\left(R_n^b(g) - R^b(g) \leq -\bar{\varepsilon}/2\right) \\ &\leq |\mathcal{C}| e^{-n\bar{\varepsilon}^2/2} \end{aligned}$$

(voir aussi le Théorème III-2.7). Il vient

$$n \geq n_1(p, \varepsilon, \delta) := \frac{2}{\bar{\varepsilon}^2} \{\log(|\mathcal{C}|) + \log(2/\delta)\} .$$

4. En utilisant la question 1, nous avons

$$R(\hat{g}_n^*) - R(g^*) = \frac{1}{1-2p} \left(R^b(\hat{g}_n^*) - R^b(g^*) \right) .$$

Nous écrivons

$$R^b(\hat{g}_n^*) - R^b(g^*) \leq R^b(\hat{g}_n^*) - R_n^b(\hat{g}_n^*) + R_n^b(\hat{g}_n^*) - R_n^b(g^*) + R_n^b(g^*) - R^b(g^*)$$

Par définition de \hat{g}_n^* , le terme $R_n^b(\hat{g}_n^*) - R_n^b(g^*)$ est négatif ; il vient

$$R(\hat{g}_n^*) - R(g^*) \leq \frac{1}{1-2p} \left(\sup_{g \in \mathcal{C}} \{R^b(g) - R_n^b(g)\} + R_n^b(g^*) - R^b(g^*) \right) .$$

Par suite

$$\begin{aligned} \mathbb{P}(R(\hat{g}_n^*) - R(g^*) > \varepsilon) &\leq \mathbb{P}\left(\sup_{g \in \mathcal{C}} \{R^b(g) - R_n^b(g)\} + R_n^b(g^*) - R^b(g^*) > \bar{\varepsilon}\right) \\ &\leq \mathbb{P}\left(\sup_{g \in \mathcal{C}} \{R^b(g) - R_n^b(g)\} > \bar{\varepsilon}/2\right) + \mathbb{P}\left(R_n^b(g^*) - R^b(g^*) > \bar{\varepsilon}/2\right) \end{aligned}$$

En utilisant les questions 2 (voir Eq. (3)) et 3, chacun des deux termes de droite est inférieur à $\delta/2$ dès lors que $n \geq n_0 \vee n_1$ i.e.

$$n \geq n(p, \varepsilon, \delta) := \frac{2}{\varepsilon^2(1 - 2p)^2} \{\log(|\mathcal{C}|) + \log(2/\delta)\}$$

5. Observons que

$$n(p, \varepsilon, \delta) = \frac{1}{(1 - 2p)^2} n(0, \varepsilon, \delta) .$$

Par suite, pour obtenir la précision (ε, δ) , nous avons

$$n(0.05, \varepsilon, \delta) = \frac{100}{81} n(0, \varepsilon, \delta) \approx 1.23 n(0, \varepsilon, \delta) .$$