

Dans tout l'énoncé,

- Les vecteurs sont des vecteurs colonnes.
- Leb est la mesure de Lebesgue sur \mathbb{R} et $\text{Leb}^{\otimes n}$ est la mesure de Lebesgue sur \mathbb{R}^n .
- Pour $p > 0$ et $\lambda > 0$, on appelle loi Gamma(p, λ), la loi de densité donnée par [**attention : convention différente du polycopié**] :

$$f_{p,\lambda}(x) := \frac{\lambda^{-p}}{\Gamma(p)} \exp(-x/\lambda) x^{p-1}, \quad x > 0.$$

On note Gcdf_p et Gqf_p la fonction de répartition et la fonction quantile de la Gamma($p, 1$).

Nous rappelons

- Si la variable aléatoire Y est distribuée suivant une loi Gamma(p, λ) avec $p > 0$, $\lambda > 0$, alors Y/λ est distribuée suivant une loi Gamma($p, 1$).
- Si la variable aléatoire Y est distribuée suivant une loi Gamma(p, λ) avec $p > 0$, $\lambda > 0$ alors $\mathbb{E}[Y] = p\lambda$ et $\text{Var}(Y) = p\lambda^2$.
- La loi du χ^2 centré à n degrés de liberté est une loi Gamma($n/2, 2$).
- Soit (X_1, \dots, X_n) n variables aléatoires indépendantes, et pour tout $i \in \{1, \dots, n\}$, la loi de X_i est la loi Gamma(p_i, λ) pour $p_i > 0$, $\lambda > 0$. Alors, $\sum_{i=1}^n X_i$ est distribuée suivant une loi Gamma($\sum_{i=1}^n p_i, \lambda$).

Exercice 1. Soit $Z = (X_1, \dots, X_n)$ un n -échantillon du modèle $(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+), \{p_\theta \cdot d\text{Leb}, \theta \in \Theta := \mathbb{R}_+^*\})$ où p_θ est la densité de Weibull définie par

$$x \mapsto p_\theta(x) = \frac{c}{\theta} x^{c-1} e^{-x^c/\theta} \mathbb{1}_{\mathbb{R}_+}(x), \quad c \text{ est une constante positive connue}$$

Soit $\theta_0 > 0$. On considère le test

$$H_0 : \theta \leq \theta_0, \quad \text{contre} \quad H_1 : \theta > \theta_0.$$

1. Montrer que, pour tout $\theta \in \Theta$, $(X_i)^c$ est, sous \mathbb{P}_θ , distribuée suivant une loi exponentielle de paramètre θ , de densité $q_\theta(y) := \theta^{-1} e^{-y/\theta} \mathbb{1}_{\mathbb{R}_+}(y)$ [qui est aussi Gamma($1, \theta$)].
2. Montrer que la famille $\{p_\theta(\cdot), \theta \in \Theta\}$ est à rapport de vraisemblance monotone.
3. Soit $\alpha \in]0, 1[$. Déterminer un test U.P.P.(α) pour ces hypothèses. On explicitera le calcul des constantes dans la définition de la fonction critique du test en fonction de la fonction quantile $\text{Gqf}_n(\cdot)$.
4. Montrer que la fonction puissance du test est donnée par

$$\theta \mapsto 1 - \text{Gcdf}_n(\theta_0 \text{Gqf}_n(1 - \alpha)/\theta)$$

Exercice 2. Soit (X_1, \dots, X_n) un n -échantillon du modèle $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{p_\theta \cdot d\text{Leb}, \theta \in \Theta\})$, où $\theta := (\mu, \sigma^2) \in \Theta := \mathbb{R} \times \mathbb{R}_+^*$, et p_θ est la densité de probabilité d'une loi Gaussienne de moyenne μ et variance σ^2 . Nous considérons les estimateurs de μ^2 donnés par

$$T_{1,n} := (\bar{X}_n)^2 \quad \text{où} \quad \bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i$$

$$T_{2,n} := (\bar{X}_n)^2 - \frac{1}{n} S_n^2 \quad \text{où} \quad S_n^2 := \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

On rappelle que Y est une variable aléatoire gaussienne centrée réduite, alors $\mathbb{E}[Y^4] = 3$.

1. Montrer que, pour tout $\theta \in \Theta$, sous $\mathbb{P}_{n,\theta}$
 - (a) la variable aléatoire \bar{X}_n suit une loi gaussienne dont on déterminera la moyenne et la variance.
 - (b) la variable S_n^2 est indépendante de \bar{X}_n et $(n-1)S_n^2/\sigma^2$ est distribuée suivant une loi Gamma dont on précisera les paramètres.
 - (c) Montrer que $\mathbb{E}_\theta[S_n^2] = \sigma^2$ and $\mathbb{E}_\theta[S_n^4] = \sigma^4(1 + 2/(n-1))$.
2. Calculer le biais de l'estimateur et le risque quadratique de l'estimateur $T_{1,n}$ de μ^2 .
3. Calculer le biais et le risque quadratique de l'estimateur $T_{2,n}$ de μ^2 .
4. L'estimateur $T_{1,n}$ de μ^2 est-il admissible pour le risque quadratique ?
5. Montrer que les suites d'estimateurs $\{T_{1,n}, n \geq 2\}$ et $\{T_{2,n}, n \geq 2\}$ sont consistantes.
6. Montrer que pour tout $\theta = (\mu, \sigma^2) \in \mathbb{R}^* \times \mathbb{R}_+^*$ (i.e. $\mu \neq 0$), $\sqrt{n}(T_{1,n} - \mu^2)$ converge sous $\mathbb{P}_{n,\theta}$ vers une loi gaussienne dont on déterminera la variance. Même question pour $\sqrt{n}(T_{2,n} - \mu^2)$.
7. Montrer que pour tout θ tel que $\mu = 0$, $nT_{1,n}$ converge en loi sous $\mathbb{P}_{n,\theta}$ vers une loi que l'on caractérisera. Même question pour $nT_{2,n}$. Commenter.

Exercice 3. Soit $Z := (X_1, \dots, X_n)$ un n -échantillon du modèle statistique du modèle exponentiel translaté $\mathcal{E}(a, \lambda)$ de densité par rapport à la mesure de Lebesgue

$$(\mathbb{R}; \mathcal{B}(\mathbb{R}); \{f_\theta \cdot \text{Leb}, \theta := (a, \lambda) \in \Theta := \mathbb{R} \times \mathbb{R}_+^*\}), \quad \text{où} \quad f_\theta(x) := \lambda^{-1} e^{-(x-a)/\lambda} \mathbb{1}_{[a, \infty[}(x)$$

Nous notons, pour $\theta \in \Theta$,

$$p_\theta(x_1, \dots, x_n) := \prod_{k=1}^n f_\theta(x_k),$$

et $\mathbb{P}_\theta := p_\theta \cdot \text{Leb}^{\otimes n}$. Soit $X_{1:n} \leq X_{2:n} \leq \dots \leq X_{n:n}$ les statistiques d'ordre de l'échantillon ; puisque les variables aléatoires $(X_k)_{k=1}^n$ ont des lois à densité par rapport à la mesure de Lebesgue, on a $\mathbb{P}_\theta(X_i = X_j) = 0$ pour tout $i \neq j$ et $\theta \in \Theta$. Par suite, il existe, \mathbb{P}_θ -p.s. une unique permutation, que nous notons $\sigma(Z) = [\sigma_1(Z), \dots, \sigma_n(Z)]$ de $\{1, \dots, n\}$ telle que

$$X_{k:n} = X_{\sigma_k(Z)}, \quad X_{\sigma_1(Z)} < X_{\sigma_2(Z)} < \dots < X_{\sigma_n(Z)}, \quad \mathbb{P}_\theta - \text{p.s.}$$

Nous notons \mathcal{S}_n l'ensemble des permutations de l'ensemble $\{1, \dots, n\}$.

1. Montrer que pour toute fonction h mesurable bornée

$$\mathbb{E}_\theta [h(X_{1:n}, \dots, X_{n:n})] = \sum_{\tau \in \mathcal{S}_n} \mathbb{E}_\theta \left[h(X_{\tau_1}, \dots, X_{\tau_n}) \mathbb{1}_{\{X_{\tau_1} < X_{\tau_2} < \dots < X_{\tau_n}\}} \right] \quad (1)$$

2. En déduire que sous \mathbb{P}_θ , la loi jointe des statistiques d'ordre $X_{1:n}, X_{2:n}, \dots, X_{n:n}$ admet une densité par rapport à $\text{Leb}^{\otimes n}$, densité donnée par

$$(y_1, \dots, y_n) \mapsto \varphi(\theta; y_1, y_2, \dots, y_n) := n! p_\theta(y_1, \dots, y_n) \mathbb{1}_{\{a \leq y_1 < y_2 < \dots < y_n\}}.$$

On considère la transformation

$$U_1 := nX_{1:n}, \quad U_k := (n - k + 1)(X_{k:n} - X_{(k-1):n}), \quad \text{pour } k \in \{2, \dots, n\}; \quad (2)$$

Remarquons que pour tout $(u_1, \dots, u_n) \in \mathbb{R}^n$,

$$\sum_{i=1}^n u_i = nu_1 + \sum_{i=2}^n (n - i + 1)(u_i - u_{i-1}). \quad (3)$$

3. Montrer que, sous \mathbb{P}_θ , les variables aléatoires (U_1, \dots, U_n) sont indépendantes. Déterminer également la loi de chacune de ces variables.
4. Démontrer que sous \mathbb{P}_θ , la statistique $T_1 := \sum_{i=1}^n (X_{i:n} - X_{1:n})$ est indépendante de $X_{1:n}$ et suit une loi $\text{Gamma}(n - 1, \lambda)$.
5. Construire, en utilisant T_1 , un intervalle de confiance pour λ avec une probabilité de couverture de $1 - \alpha$, où $\alpha \in]0, 1[$.
6. Établir que sous \mathbb{P}_θ , la statistique $T_2 := X_{1:n}$ suit une loi $\mathcal{E}(a, \lambda/n)$.
7. Justifier *sans calcul* que la fonction $a \mapsto F_n(a) := (T_2 - a)/\{(n - 1)^{-1}T_1\}$ est pivotale pour le paramètre θ .
8. **Question bonus !** Prouver que, pour tout $\theta \in \Theta$, la loi de $F_n(a)$ par rapport à la mesure de Lebesgue est donnée par l'équation suivante :

$$t \mapsto n \left(1 + \frac{nt}{n-1} \right)^{-n} \mathbb{1}_{[0, \infty[}(t). \quad (4)$$

9. En se servant de la fonction pivotale $F_n(a)$, construire un intervalle de confiance pour a avec une probabilité de couverture de $1 - \alpha$.

Exercice 4. On cherche à expliquer une variable quantitative Y_i (réponse) par une régression linéaire à un facteur $[1, x_i]^\top$, $i \in \{1, \dots, n\}$, $x_i \in \mathbb{R}$. On pose $\theta := (\beta, \sigma^2) \in \Theta := \mathbb{R} \times \mathbb{R}^* \times \mathbb{R}_+^*$, avec $\beta := [\beta_0, \beta_1]^\top$. Nous posons $\mathbf{Y} := [Y_1, \dots, Y_n]^\top$, $\mathbf{y} := [y_1, \dots, y_n]^\top$. Nous supposons que, pour tout $\theta \in \Theta$, \mathbf{Y} est un vecteur Gaussien, de moyenne $[\beta_0 + \beta_1 x_1, \dots, \beta_0 + \beta_1 x_n]^\top$ et de covariance $\sigma^2 \mathbf{I}_n$, i.e. la densité de \mathbf{Y} par rapport à la mesure de Lebesgue sur \mathbb{R}^n est

$$p_\theta(\mathbf{y}) := \frac{1}{\sqrt{2\pi\sigma^2}^n} \exp \left(-\frac{1}{2} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2 \right)$$

Posons $\mathbf{x} := [x_1, \dots, x_n]^\top$, $\mathbf{1} := [1, \dots, 1]^\top \in \mathbb{R}^n$, et $\mathbf{X} := [\mathbf{1}, \mathbf{x}]$. Avec ces notations, nous pouvons écrire de façon équivalente

$$p_\theta(\mathbf{y}) = \frac{1}{\sqrt{2\pi\sigma^2}^n} \exp \left(-\frac{1}{2} \|\mathbf{Y} - \mathbf{X}\beta\|^2 \right)$$

Nous supposons que la matrice \mathbf{X} , de taille $n \times 2$, est de rang 2 et nous posons $H := \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ le projecteur orthogonal sur $\text{Vect}(\mathbf{X})$.

Nous notons

$$\bar{Y} := \frac{1}{n} \sum_{i=1}^n Y_i = \frac{\mathbf{1}^\top \mathbf{Y}}{\|\mathbf{1}\|^2} \quad \text{et} \quad \bar{x} := \frac{1}{n} \sum_{i=1}^n x_i = \frac{\mathbf{1}^\top \mathbf{x}}{\|\mathbf{1}\|^2}.$$

1. Montrer que les estimateurs du maximum de vraisemblance $\hat{\beta} := [\hat{\beta}_0, \hat{\beta}_1]^\top$ et $\hat{\sigma}^2$ de (β_0, β_1) et σ^2 sont donnés par

$$\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{bmatrix} := (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} = \begin{bmatrix} \bar{Y} - \hat{\beta}_1 \bar{x} \\ \frac{\sum_{i=1}^n Y_i (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{bmatrix} \quad (5)$$

$$\hat{\sigma}^2 := \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = \frac{1}{n} \|(\mathbf{I}_n - H) \mathbf{Y}\|^2 \quad (6)$$

Nous remarquons que \mathbb{P}_{θ} -p.s., $\hat{\beta}_1 \neq 0$.

2. Démontrer que, sous $\mathbb{P}_{\beta, \sigma^2}$, $\hat{\beta}$ est un vecteur gaussien dont on précisera la moyenne et la covariance.
3. Montrer que les statistiques $\hat{\sigma}^2$ et $\hat{\beta}$ sont indépendantes. Déterminer la distribution de la statistique $\hat{\sigma}^2$.

Nous posons, $S^2 := (n/(n-2))\hat{\sigma}^2$ et pour $\beta := [\beta_0, \beta_1]^\top \in \mathbb{R} \times \mathbb{R}^*$: $\phi := -\beta_0/\beta_1$, et $\delta := -\phi + \bar{x}$.

4. Montrer que, pour tout $\theta \in \Theta$,

$$\mathbb{E}_{\theta} [\bar{Y} - \delta \hat{\beta}_1] = 0.$$

5. Montrer que, pour tout $\theta \in \Theta$,

$$\text{Cov}_{\theta}(\bar{Y}, \hat{\beta}_1) = 0.$$

6. Montrer que, pour tout $\theta \in \Theta$,

$$\text{Var}_{\theta}(\bar{Y} - \delta \hat{\beta}_1) = \sigma^2 w(\delta) \quad \text{où} \quad w(\delta) := \frac{1}{n} + \frac{\delta^2}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

7. Montrer que pour tout $\theta \in \Theta$, sous \mathbb{P}_{θ} , $\bar{Y} - \delta \hat{\beta}_1$ est distribué suivant une loi normale centrée de variance $\sigma^2 w(\delta)$ et est indépendante de S^2 .

Nous posons

$$T(\delta) := \frac{\bar{Y} - \delta \hat{\beta}_1}{S \sqrt{w(\delta)}}$$

8. Montrer que pour tout $\theta \in \Theta$, sous \mathbb{P}_{θ} , $T^2(\delta)$ est distribuée suivant une loi de Fisher à $(1, n-2)$ degrés de liberté.
9. En déduire une région de confiance pour δ de probabilité de couverture $1 - \alpha$, $\alpha \in]0, 1[$, de la forme $A(\alpha)\delta^2 + B(\alpha)\delta + C(\alpha) \leq 0$ [on déterminera $A(\alpha)$, $B(\alpha)$, et $C(\alpha)$]. Sous quelle condition cette région de confiance est-elle un intervalle ?

Exercice 5. Dans cet exercice, nous considérons des observations i.i.d. $(X_i, Y_i)_{1 \leq i \leq n}$ où Y_i prend des valeurs dans $\{-1, 1\}$ et X_i prend des valeurs dans \mathbb{R}^d . Pour un x donné dans \mathbb{R}^d , nous considérerons le classificateur suivant : $\hat{h}_n(x) = Y_{\phi_n(x)}$ où

$$\phi_n(x) = \arg \min_{i \in [1:n]} \|x - X_i\|$$

En d'autres termes, $\phi_n(x)$ est l'indice du voisin le plus proche de x parmi l'ensemble de données $\{X_i; i \in [1 : n]\}$. Dans tout l'exercice, nous considérons une paire de variables aléatoires (X, Y) ayant la même loi que (X_i, Y_i) pour tout $i \geq 1$. Et pour éviter toute ambiguïté dans la définition de l'indice $\phi_n(X)$, nous supposons qu'avec probabilité 1, tous les $\|X - X_i\|$ pour tout $i \in \mathbb{N}$ sont strictement différents.

Rappelons que le classificateur optimal de Bayes est défini par

$$h^*(X) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1|X) > \mathbb{P}(Y = -1|X) \\ -1 & \text{sinon} \end{cases}$$

et rappelons qu'en définissant $\eta(X) = \mathbb{P}(Y = 1|X)$ et $r^*(X) = \min(\eta(X), 1 - \eta(X))$, nous avons

$$R^* = \mathbb{P}(Y \neq h^*(X)) = \mathbb{E}[r^*(X)] \leq \mathbb{P}(Y \neq h(X))$$

pour tout autre classificateur $h : \mathbb{R}^d \rightarrow \{-1, 1\}$. Le but de cet exercice est de montrer la borne

$$R^* \leq \lim_{n \rightarrow \infty} \mathbb{P}(Y \neq \hat{h}_n(X)) \leq 2R^*(1 - R^*)$$

Définissons $X_{(n)} = X_{\phi_n(X)}$ le voisin le plus proche de X parmi l'ensemble $\{(X_i); i \in [1 : n]\}$. Nous admettons que,

— la suite $\{X_{(n)}, (n) \in \mathbb{N}\}$ converge en probabilité vers X :

$$X_{(n)} \xrightarrow{\mathbb{P}\text{-prob}} X ,$$

— la fonction η est continue,

1. Montrez que, pour tout $x \in \mathbb{R}^d$, $r^*(x)(1 - r^*(x)) = \eta(x)(1 - \eta(x))$.
2. Montrez que pour tout $i \in [1 : n]$, nous avons presque sûrement,

$$\mathbb{P}(Y = -1, Y_i = 1, \phi_n(X) = i | X, X_{1:n}) = (1 - \eta(X))\eta(X_i)\mathbb{1}_{\{i\}}(\phi_n(X))$$

3. En notant que, $\eta(X_{(n)}) = \sum_{i=1}^n \eta(X_i)\mathbb{1}_{\{i\}}(\phi_n(X))$, déduisez que, presque sûrement,

$$\mathbb{P}(Y = -1, \hat{h}_n(X) = 1 | X, X_{1:n}) = (1 - \eta(X))\eta(X_{(n)}),$$

4. De la même manière, montrez que

$$\mathbb{P}(Y = 1, \hat{h}_n(X) = -1 | X, X_{1:n}) = \eta(X)(1 - \eta(X_{(n)})),$$

5. Montrez que $\lim_{n \rightarrow \infty} \mathbb{E}[\eta(X_{(n)})] = \mathbb{E}[\eta(X)]$.

6. Montrez que :

$$\lim_{n \rightarrow \infty} \mathbb{P}(Y \neq \hat{h}_n(X)) = 2\mathbb{E}[r^*(X)(1 - r^*(X))]$$

7. Déduisez que

$$\lim_{n \rightarrow \infty} \mathbb{P}(Y \neq \hat{h}_n(X)) \leq 2R^*(1 - R^*)$$

et conclure.

Solution . [Exercice 1]

1. Soit h une fonction borélienne bornée. Pour tout $\theta \in \Theta$, nous avons, en utilisant le changement de variable $y = x^c$

$$\begin{aligned}\mathbb{E}_\theta[h(X_1^c)] &= \int_0^{+\infty} h(x^c) \theta^{-1} c x^{c-1} \exp(-x^c/\theta) dx \\ &= \int_0^{+\infty} h(y) \theta^{-1} \exp(-y/\theta) dy .\end{aligned}$$

2. Pour tout $(x_1, \dots, x_n) \in \mathbb{R}^+$, nous avons

$$p_\theta(x_1, \dots, x_n) = \theta^{-n} c^n \prod_{i=1}^n x_i^c e^{-\sum_{i=1}^n x_i^c/\theta}.$$

qui est de la forme $p_\theta(z) = h(z)\psi(T(z); \theta)$ avec $T(z) = \sum_{i=1}^n x_i^c$, $h(z) = c^n \prod_{i=1}^n x_i^c$ et $\psi(t, \theta) = \exp(-t/\theta - n \ln(\theta))$.

3. Pour $\theta > \theta'$, le rapport

$$\frac{\psi(t; \theta)}{\psi(t; \theta')} = \exp\left(t \frac{\theta - \theta'}{\theta\theta'} - n \ln(\theta/\theta')\right)$$

est une fonction monotone croissante de t . La fonction critique du test U.P.P.(α) est donné par $\phi(z) = \mathbb{1}_{\{T(z) > c\}}$ où c est donné par

$$\mathbb{P}_{\theta_0}(T(Z) > c) = \alpha .$$

Sous \mathbb{P}_{θ_0} , $T(Z)$ est distribué suivant (voir (1)) suivant une loi Gamma(n, θ_0); par conséquent, $T(Z)/\theta_0$ est distribué suivant une loi Gamma($n, 1$). Le seuil critique du test est donc donné par $c = \theta_0 \text{Gqf}_n(1 - \alpha)$.

4. La fonction puissance du test est donnée par

$$\beta_\phi(\theta) = \mathbb{P}_\theta(T(Z) > \theta_0 \text{Gqf}_n(1 - \alpha))$$

Comme sous \mathbb{P}_θ , pour tout $\theta \in \Theta$, $T(Z)/\theta$ est distribuée suivant une loi Gamma($n, 1$), nous avons

$$\beta_\phi(\theta) = \mathbb{P}_\theta(T(Z)/\theta > \theta_0 \text{Gqf}_n(1 - \alpha)/\theta) = 1 - \text{Gcdf}_n(\theta_0 \text{Gqf}_n(1 - \alpha)/\theta)$$

Solution . [Exercice 2]

1. Il s'agit d'une application directe du théorème IV.3.24
 - (a) \bar{X}_n est distribuée suivant une loi gaussienne de moyenne μ et de variance σ^2/n .
 - (b) $(n-1)S_n^2/2$ est distribuée suivant une loi du χ^2 centré à $(n-1)$ degrés de liberté, donc une loi Gamma($(n-1)/2, 2$) en utilisant le rappel.
 - (c) Nous avons

$$\mathbb{E}_\theta[S_n^4] = \frac{\sigma^4}{(n-1)^2} \left[\left(\frac{n-1}{\sigma^2} S_n^2 \right)^2 \right] = \sigma^4 \left(1 + \frac{2}{n-1} \right)$$

2. En utilisant la décomposition biais-variance de l'erreur quadratique et les résultats de la question précédente, il vient

$$\mathbb{E}_{n,\theta}[\bar{X}_n^2] = \mu^2 + \sigma^2/n,$$

dont on déduit que le biais de l'estimateur est σ^2/n .

Sous \mathbb{P}_θ , $\bar{X}_n - \mu$ est une variable aléatoire gaussienne de moyenne nulle et de variance σ^2/n . centrée; remarquons que son moment d'ordre 3 sont nuls; son moment d'ordre 2 est égal à sa variance. Le risque quadratique vaut, par définition : $\mathbb{E}_{n,\theta}[(\bar{X}_n^2 - \mu^2)^2]$. Nous avons

$$\begin{aligned}\mathbb{E}_\theta[(\bar{X}_n^2 - \mu^2)^2] &= \mathbb{E}_\theta[(\{\bar{X}_n - \mu + \mu\}^2 - \mu^2)^2] \\ &= \mathbb{E}_\theta[(\{\bar{X}_n - \mu\}^2 + 2\mu\{\bar{X}_n - \mu\})^2] = \mathbb{E}_\theta[(\bar{X}_n - \mu)^4] + 4\mu^2\sigma^2/n\end{aligned}$$

en utilisant la question précédente dans la dernière égalité. En utilisant le rappel sur le moment d'ordre 4 d'une loi gaussienne centrée réduite, nous en déduisons

$$\mathbb{E}_\theta[(\bar{X}_n^2 - \mu^2)^2] = 3\frac{\sigma^4}{n^2} + 4\mu^2\frac{\sigma^2}{n}.$$

3. Nous avons

$$\mathbb{E}_{n,\theta}[T_{2,n}] = \mathbb{E}_{n,\theta}[T_{1,n}] - \frac{1}{n}\mathbb{E}_{n,\theta}[S_n^2] = \mu^2 + \frac{\sigma^2}{n} - \frac{1}{n}\mathbb{E}_{n,\theta}[S_n^2].$$

En utilisant (1), S_n^2 est une estimateur sans biais de la variance des variables aléatoires $\{X_i\}_{i=1}^n$; par suite : $\mathbb{E}_{n,\theta}[S_n^2] = \sigma^2$. On en déduit que

$$\mathbb{E}_{n,\theta}[T_{2,n}] = \mu^2$$

et l'estimateur est sans biais.

4. Soit $\varepsilon > 0$. D'après l'inégalité de Markov

$$\mathbb{P}_{n,\theta}[|T_{1,n} - \mu^2| \geq \varepsilon] \leq \frac{1}{\varepsilon^2}\mathbb{E}_{n,\theta}[|T_{1,n} - \mu^2|^2].$$

En utilisant la question 2, $\lim_{n \rightarrow \infty} \mathbb{E}_{n,\theta}[|T_{1,n} - \mu^2|^2] = 0$ dont on déduit la convergence en probabilité de $T_{1,n}$ vers μ^2 . Ainsi, la suite $\{T_{1,n}, n \geq 2\}$ est consistante.

Nous avons

$$T_{2,n} = T_{1,n} - \frac{1}{n}S_n^2.$$

Nous venons d'établir que $T_{1,n} \xrightarrow{\mathbb{P}_{n,\theta-\text{prob}}} \mu^2$. Par ailleurs, la loi faible des grands nombres entraîne que $(n-1)S_n^2/n \xrightarrow{\mathbb{P}_{n,\theta-\text{prob}}} \sigma^2$. Nous en déduisons, par le lemme de Slutsky, que $S_n^2/n \xrightarrow{\mathbb{P}_{n,\theta}} 0$ et donc $S_n^2/n \xrightarrow{\mathbb{P}_{n,\theta-\text{prob}}} 0$. Par suite $T_{2,n} \xrightarrow{\mathbb{P}_{n,\theta-\text{prob}}} \mu^2$.

5. Etudions la loi asymptotique de $\sqrt{n}(T_{1,n} - \mu^2)$. Nous écrivons $T_{1,n} = g(\bar{X}_n)$ où g est la fonction de classe C^1 sur \mathbb{R} définie par $g(x) := x^2$. Le TLC pour des v.a. i.i.d. entraîne

que $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{\mathbb{P}_{n,\theta}} N(0, \sigma^2)$. En appliquant la méthode delta avec la fonction g , nous avons

$$\sqrt{n}(T_{1,n} - g(\mu)) \xrightarrow{\mathbb{P}_{n,\theta}} g'(\mu) N(0, \sigma^2) \equiv N(0, 4\mu^2 \sigma^2).$$

Etudions la loi asymptotique de $\sqrt{n}(T_{2,n} - \mu^2)$. Nous écrivons

$$\sqrt{n}(T_{2,n} - \mu^2) = \sqrt{n}(T_{1,n} - \mu^2) - \frac{1}{\sqrt{n}} S_n^2.$$

Nous avons $S_n^2 \xrightarrow{\mathbb{P}_{n,\theta} - \text{prob}} \sigma^2$, dont nous déduisons que $S_n^2/\sqrt{n} \xrightarrow{\mathbb{P}_{n,\theta} - \text{prob}} 0$. De plus, nous venons de prouver la normalité asymptotique du premier terme. Par le lemme de Slutsky, nous en déduisons que $\sqrt{n}(T_{2,n} - \mu^2)$ et $\sqrt{n}(T_{1,n} - \mu^2)$ ont même limite en loi :

$$\sqrt{n}(T_{2,n} - \mu^2) \xrightarrow{\mathbb{P}_{n,\theta}} N(0, 4\mu^2 \sigma^2).$$

6. Soit θ tel que $\mu = 0$. Nous avons

$$nT_{1,n} = \frac{1}{n} \left(\sum_{i=1}^n X_i \right)^2 = \left(\frac{1}{\sqrt{n}} \sum_{i=1}^n X_i \right)^2.$$

Or, sous $\mathbb{P}_{n,\theta}$, $X_i \sim N(0, \sigma^2)$ et les v.a. X_i sont i.i.d. Par suite, sous $\mathbb{P}_{n,\theta}$, $\sum_{i=1}^n X_i \sim N(0, n\sigma^2)$ dont on déduit que

$$\frac{1}{\sqrt{n}\sigma} \sum_{i=1}^n X_i \sim N(0, 1).$$

Nous avons donc établi que sous $\mathbb{P}_{n,\theta}$

$$nT_{1,n} = \left(\frac{1}{\sqrt{n}} \sum_{i=1}^n X_i \right)^2 \sim \sigma^2 \chi^2(1).$$

Nous avons

$$nT_{2,n} = nT_{1,n} - S_n^2.$$

Puisque $S_n^2 \xrightarrow{\mathbb{P}_{n,\theta} - \text{prob}} \sigma^2$, nous déduisons du lemme de Slutsky que

$$nT_{2,n} \xrightarrow{\mathbb{P}_{n,\theta}} \sigma^2 (\chi^2(1) - 1).$$

Solution . 1. Par construction nous avons

$$\begin{aligned} \mathbb{E}_\theta[h(X_{1:n}, \dots, X_{n:n})] &= \mathbb{E}_\theta[h(X_{\sigma_1(Z)}, \dots, X_{\sigma_n(Z)})] \\ &= \sum_{\tau \in \mathcal{S}_n} \mathbb{E}_\theta[h(X_{\tau_1}, \dots, X_{\tau_n}) \mathbb{1}_{\{\tau = \sigma(Z)\}}] = \sum_{\tau \in \mathcal{S}_n} \mathbb{E}_\theta[h(X_{\tau_1}, \dots, X_{\tau_n}) \mathbb{1}_{\{X_{\tau_1} < \dots < X_{\tau_n}\}}] \end{aligned}$$

2. Comme sous \mathbb{P}_θ , $(X_{\tau_1}, \dots, X_{\tau_n})$ a la même loi que X_1, \dots, X_n , nous en déduisons

$$\mathbb{E}_\theta[h(X_{1:n}, \dots, X_{n:n})] = n! \iint h(y_1, \dots, y_n) p_\theta(y_1, \dots, y_n) \mathbb{1}_{\{y_1 < \dots < y_n\}} d\text{Leb}^{\otimes n}(y_1, \dots, y_n)$$

3. Soit h une fonction mesurable bornée. Notons que

$$\begin{aligned}\mathbb{E}_\theta[h(U_1, \dots, U_n)] &= \mathbb{E}_\theta[h(nX_{1:n}, (n-1)(X_{2:n} - X_{1:n}), \dots, X_{n:n})] \\ &= n! \iint h(ny_1, (n-2)(y_2 - y_1), \dots, y_n) \lambda^{-n} \exp\left(-\lambda^{-1} \sum_{i=1}^n (y_i - a)\right) \mathbb{1}_{\{a < y_1 < \dots < y_n\}} d\text{Leb}^\otimes(y_1, \dots, y_n) \\ &= n! \iint h(ny_1, (n-2)(y_2 - y_1), \dots, y_n) \lambda^{-n} \exp(-\lambda^{-1}n(y_1 - a)) \\ &\quad \times \prod_{i=2}^n \exp(\lambda^{-1}(n-i+2)(y_i - y_{i-1})) \mathbb{1}_{\{a < y_1 < \dots < y_n\}} d\text{Leb}^\otimes(y_1, \dots, y_n)\end{aligned}$$

où nous avons utilisé (3). Nous en déduisons

$$\begin{aligned}\mathbb{E}_\theta[h(U_1, \dots, U_n)] &= \iint h(u_1, \dots, u_n) \lambda^{-n} \exp(-\lambda^{-1}(u_1 - na)) \prod_{i=2}^n \exp(-\lambda^{-1}u_i) \mathbb{1}_{\mathbb{R}^+}(u_i) \mathbb{1}_{\{a < u_1\}} d\text{Leb}^\otimes(u_1, \dots, u_n)\end{aligned}$$

ce qui démontre que les variables U_1, U_2, \dots, U_n sont indépendantes sous \mathbb{P}_θ . La variable U_1 est distribuée suivant une loi $\mathcal{E}(na, \lambda)$. Les variables U_2, \dots, U_n sont distribuées suivant une loi $\mathcal{E}(0, \lambda)$.

4. En utilisant (3), nous avons

$$\sum_{i=1}^n (X_{i:n} - X_{1:n}) = \sum_{i=2}^n (n-i+1)(X_{i:n} - X_{i-1:n}) = \sum_{i=2}^n U_i.$$

Comme sous \mathbb{P}_θ , les variables aléatoires U_2, \dots, U_n sont indépendantes de loi Gamma(1, λ), $\sum_{i=2}^n U_i$ est distribuée suivant une loi Gamma($n-1$, λ).

5. Pour tout $\theta \in \Theta$, la fonction T_1/λ est distribuée suivant la loi Gamma($n-1$, 1). Elle est donc pivotale. En notant $a_\alpha = \text{Gqf}(\alpha/2)$ et $b_\alpha = \text{Gqf}(1-\alpha/2)$ on a donc pour tout $\theta \in \Theta$,

$$\mathbb{P}_\theta(T_1/\lambda \in [a_\alpha, b_\alpha]) = 1 - \alpha.$$

Par conséquent, $[T_1/b_\alpha, T_1/a_\alpha]$ est un intervalle de confiance de couverture $1 - \alpha$.

6. Comme $nX_{1:n}$ est distribué suivant une loi $\mathcal{E}(na, \lambda)$, nous avons pour toute fonction h mesurable bornée

$$\begin{aligned}\mathbb{E}_\theta[h(X_{1:n})] &= \mathbb{E}_\theta[h(U_1/n)] = \int h(u_1/n) \lambda^{-1} \exp(\lambda^{-1}(u_1 - na)) \mathbb{1}_{\{u_1 \geq na\}} d\text{Leb}(u_1) \\ &\quad \int (n/\lambda) h(v_1) \exp((n/\lambda)(v_1 - a)) \mathbb{1}_{\{v_1 \geq a\}} d\text{Leb}(v_1)\end{aligned}$$

et donc $X_{1:n}$ est $\mathcal{E}(a, \lambda/n)$.

7. Sous \mathbb{P}_θ , $(T_2 - a)/\lambda$ est $\mathcal{E}(0, 1)$ et est indépendant de T_1/λ qui est distribuée suivant une loi Gamma($n-1$, 1). La fonction $F_n(a)$ est donc pivotale.

8. **[Question bonus]** : Soit h une fonction mesurable bornée. Nous avons

$$\begin{aligned}\mathbb{E}_\theta[h(F_n(a))] &= \int_a^{+\infty} \int_0^{+\infty} h\left(\frac{(n-1)(t_2-a)}{t_1}\right) \frac{n}{\lambda} \exp\left(-\frac{n}{\lambda}(t_2-a)\right) \frac{t_1^{n-2}}{(n-2)!\lambda^{n-1}} \exp\left(-\frac{t_1}{\lambda}\right) dt_1 dt_2 \\ &= \int_0^{+\infty} h(t) \left\{ \int \frac{nt_1^{n-1}}{(n-1)!\lambda^n} \exp\left(-\frac{t_1}{\lambda}\left(1+\frac{nt}{n-1}\right)\right) dt_1 \right\} dt\end{aligned}$$

Nous concluons en remarquant que pour tout $s > 0$,

$$\int_0^{+\infty} \frac{v^{n-1}}{\Gamma(n)} \exp(-v/s) d\text{Leb}(v) = s^n.$$

9. Choisissons deux constantes $0 < c_1 < c_2$ telles que

$$\int_{c_1}^{c_2} n \left(1 + \frac{nt}{n-1}\right)^{-n} dt = 1 - \alpha.$$

Alors un intervalle de confiance pour a de niveau de couverture $1 - \alpha$ est

$$(T_2 - c_2 T_1, T_2 - c_1 T_1).$$

Solution . 1.

2. Remarquons que $\mathbb{E}_\theta[\hat{\beta}_1] = \beta_1$ et $\mathbb{E}_\theta[\bar{Y}] = \beta_0 + \beta_1 \bar{x}$. Par conséquent :

$$\mathbb{E}_\theta[\bar{Y} - \delta \hat{\beta}_1] = \beta_0 + \beta_1 \bar{x} - \delta \beta_1 = 0$$

3. En posant $\mathbf{u} = \mathbf{x} - \bar{x}\mathbf{1}$, nous avons

$$\text{Cov}_\theta(\bar{Y}, \hat{\beta}_1) = \frac{1}{n\|\mathbf{u}\|^2} \mathbf{1}^\top \text{Cov}_\theta(Y) \mathbf{u} = \sigma^2 \frac{\mathbf{1}^\top \mathbf{u}}{n\|\mathbf{u}\|^2} = 0$$

4. Nous avons

$$\begin{aligned}\text{Var}_\theta(\bar{Y} - \delta \hat{\beta}_1) &= \text{Var}_\theta(\bar{Y}) + \delta^2 \text{Var}_\theta(\hat{\beta}_1) \\ &= \frac{\sigma^2}{n} + \delta^2 \frac{\sigma^2}{\|\mathbf{u}\|^2}.\end{aligned}$$

5. Remarquons que

$$\mathbf{Y} - \delta \hat{\beta}_1 = \mathbf{v}^\top \mathbf{Y} \quad \text{où } \mathbf{v} = \left(\frac{1}{n} \mathbf{1} - \frac{\delta}{\|\mathbf{u}\|^2} \mathbf{u} \right)^\top \mathbf{Y},$$

Par conséquent $\mathbf{Y} - \delta \hat{\beta}_1$ est un vecteur Gaussien ; la moyenne et la covariance ont été déterminées dans les deux questions précédentes.

6. Notons que $(\mathbf{I}_n - H)\mathbf{v} = 0$. Par conséquent, en utilisant le corollaire IV.3.9, les vecteurs aléatoires $\mathbf{Y} - \delta \hat{\beta}_1$ et $(\mathbf{I}_n - H)\mathbf{Y}$ sont indépendants.

7. Considérons la décomposition

$$T(\delta) = \frac{\bar{Y} - \delta \hat{\beta}_1}{\sigma \sqrt{w(\delta)}} \frac{1}{\sqrt{S^2/\sigma^2}}$$

Le numérateur est une variable Gaussienne centrée réduite. $(n-2)S^2/\sigma^2$ suit une loi du χ^2 centré à $n-2$ degrés de liberté. Donc $T^2(\delta)$ est distribué suivant une loi de Fisher à $(1, n-2)$ degrés de liberté.

8. Nous remarquons que la fonction $T^2(\delta)$ est une fonction pivotale. En notant $F_{1,n-2}^\alpha$ le quantile $1-\alpha$ de la loi de Fisher à $(1, n-2)$ d.l, nous avons pour tout $\theta \in \Theta$,

$$\mathbb{P}_\theta(T^2(\delta) \leq F_{1,n-2}^\alpha) = 1 - \alpha.$$

Ceci définit la région de confiance

$$\delta^2 \left\{ \hat{\beta}_1^2 - \frac{S^2 F_{1,n-2}^\alpha}{\sum (x_i - \bar{x})^2} \right\} - 2\delta \bar{Y} \hat{\beta}_1 + \left(\bar{Y}^2 - \frac{1}{n} S^2 F_{1,n-2}^\alpha \right) \leq 0$$

Solution . — Si $\eta(X) \leq 1/2$, alors $r^*(X) = \eta(X)$ et $r^*(X)(1 - r^*(X)) = \eta(X)(1 - \eta(X))$.
Si $\eta(X) > 1/2$, alors $r^*(X) = 1 - \eta(X)$ et $r^*(X)(1 - r^*(X)) = \eta(X)(1 - \eta(X))$.

— Nous avons

$$\begin{aligned} \mathbb{P}(Y = -1, Y_i = 1, \phi_n(X) = i | X, X_{1:n}) &= \mathbb{E} [\mathbb{1}_{\{Y=-1\}} \mathbb{1}_{\{Y_i=1\}} \mathbb{1}_{\{\phi_n(X)=i\}} | X, X_{1:n}] \\ &= \mathbb{E}(\mathbb{1}_{\{Y=-1\}} | X) \mathbb{E}(\mathbb{1}_{\{Y_i=1\}} | X_i) \mathbb{1}_{\{\phi_n(X)=i\}} \\ &= (1 - \eta(X)) \eta(X_i) \mathbb{1}_{\{\phi_n(X)=i\}} \end{aligned}$$

—

$$\begin{aligned} \mathbb{P}(Y = -1, \hat{h}_n(X) = 1 | X, X_{1:n}) &= \sum_{i=1}^n \mathbb{P}(Y = -1, Y_i = 1, \phi_n(X) = i | X, X_{1:n}) \\ &= \sum_{i=1}^n (1 - \eta(X)) \eta(X_i) \mathbb{1}_{\{\phi_n(X)=i\}} \\ &= (1 - \eta(X)) \eta(X_{(n)}) \end{aligned}$$

— Nous avons

$$\begin{aligned} \mathbb{P}(Y \neq \hat{h}_n(X)) &= \mathbb{E}[\mathbb{P}(Y = -1, \hat{h}_n(X) = 1 | X, X_{1:n})] + \mathbb{E}[\mathbb{P}(Y = 1, \hat{h}_n(X) = -1 | X, X_{1:n})] \\ &= \mathbb{E}[\eta(X_{(n)})(1 - \eta(X))] + \mathbb{E}[\eta(X)(1 - \eta(X_{(n)}))] \rightarrow 2\mathbb{E}[\eta(X)(1 - \eta(X))] \end{aligned}$$

où nous avons utilisé que $0 \leq \eta(X_{(n)})(1 - \eta(X)) \leq 1$ et $\lim_{n \rightarrow \infty} \eta(X_{(n)})(1 - \eta(X)) = \eta(X)(1 - \eta(X))$ presque sûrement. Et le même raisonnement vaut pour la deuxième espérance $\mathbb{E}[\eta(X)(1 - \eta(X_{(n)}))]$.

— C'est une simple adaptation des deux questions précédentes.

— Le résultat se tient immédiatement de la question précédente et de la première question.

— D'après la question précédente,

$$\begin{aligned}\lim_{n \rightarrow \infty} \mathbb{P}(Y \neq \hat{h}_n(X)) &= 2\mathbb{E}[r^*(X)(1 - r^*(X))] \\ &= 2 [\mathbb{E}[r^*(X)] - \mathbb{E}[r^*(X)^2]] \\ &\leq 2 [\mathbb{E}[r^*(X)] - \mathbb{E}^2[r^*(X)]] = 2R^*(1 - R^*)\end{aligned}$$

— Puisque \hat{h}_n est un classificateur, nous avons aussi

$$R^* \leq \mathbb{P}(Y \neq \hat{h}_n(X))$$

En combinant avec la question précédente, nous obtenons finalement

$$R^* \leq \lim_{n \rightarrow \infty} \mathbb{P}(Y \neq \hat{h}_n(X)) \leq 2R^*(1 - R^*)$$