

Dans ce sujet, par convention un vecteur  $x$  est un vecteur colonne. On notera  $x^T$  la transposée du vecteur (ou de la matrice)  $x$ .

**Exercice 1.** Soit  $1 \leq p \leq n - 2$  deux entiers naturels, et  $A$  une matrice de taille  $n \times p$  de rang  $p$ , connue. Soit  $(Y_1, \dots, Y_n)$  une observation du modèle statistique :

$$(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \{\mathbb{P}_\theta = p_\theta \cdot \text{Leb}^{\otimes n} : \theta = (\beta, \sigma^2) \in \Theta := \mathbb{R}^p \times \mathbb{R}_+^*\})$$

où  $\text{Leb}^{\otimes n}$  est la mesure de Lebesgue sur  $\mathbb{R}^n$  et  $p_\theta$  est une densité par rapport à  $\text{Leb}^{\otimes n}$  donnée par :

$$p_\theta(\mathbf{y}) := \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2}\|\mathbf{y} - A\beta\|^2\right); \quad \theta = (\beta, \sigma^2) \in \Theta, \quad \mathbf{y} := \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} \in \mathbb{R}^n$$

Nous notons

$$\mathbf{Y} := \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} \in \mathbb{R}^n, \quad C := A^T A \in \mathbb{R}^{p \times p}, \quad H := AC^{-1}A^T \in \mathbb{R}^{n \times n}, \quad \hat{\beta} := C^{-1}A^T \mathbf{Y} \in \mathbb{R}^p.$$

Nous rappelons que

- $H$  est le projecteur orthogonal sur  $\text{Im}(A)$ , le sous-espace vectoriel de  $\mathbb{R}^n$  engendré par les colonnes de la matrice  $A$ .
- $\hat{\beta}$  est l'estimateur des moindres carrés, i.e. l'unique minimum de

$$\beta \mapsto J(\beta) := \|\mathbf{Y} - A\beta\|^2.$$

Nous considérons maintenant un modèle dans lequel nous ajoutons un régresseur (i.e. “une variable explicative”)  $\mathbf{z} \in \mathbb{R}^{n \times 1}$  vérifiant  $(I - H)\mathbf{z} \neq \mathbf{0}_{n \times 1}$ . Nous supposons maintenant que  $(Y_1, \dots, Y_n)$  est une observation du modèle statistique

$$(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \{\mathbb{Q}_{\bar{\theta}} = q_{\bar{\theta}} \cdot \text{Leb}^{\otimes n} : \bar{\theta} = (\bar{\beta}, \gamma, \bar{\sigma}^2) \in \bar{\Theta} := \mathbb{R}^p \times \mathbb{R} \times \mathbb{R}_+^*\})$$

où  $q_{\bar{\theta}}$  est une densité par rapport à la mesure de Lebesgue sur  $\mathbb{R}^n$  donnée par :

$$q_{\bar{\theta}}(\mathbf{y}) := \frac{1}{(2\pi\bar{\sigma}^2)^{n/2}} \exp\left(-\frac{1}{2\bar{\sigma}^2}\|\mathbf{y} - A\bar{\beta} - \mathbf{z}\gamma\|^2\right); \quad \bar{\theta} = (\bar{\beta}, \gamma, \bar{\sigma}^2) \in \bar{\Theta}.$$

Nous posons

$$\mathbf{z}_\perp := (I - H)\mathbf{z}, \quad V := [A, \mathbf{z}_\perp], \quad \mathbf{k}_z := C^{-1}A^T \mathbf{z}.$$

Remarquons que

$$A^T \mathbf{z}_\perp = \mathbf{0}_{p \times 1} \quad \text{et} \quad \mathbf{z} = A\mathbf{k}_z + \mathbf{z}_\perp.$$

1. Montrer que, pour tout  $\bar{\theta} = (\bar{\beta}, \gamma, \bar{\sigma}^2) \in \bar{\Theta}$ ,

$$\mathbb{E}_{\bar{\theta}}[\mathbf{Y}] = V \begin{bmatrix} \bar{\beta} + \mathbf{k}_z \gamma \\ \gamma \end{bmatrix}.$$

2. Montrer que l'estimateur  $\hat{\lambda}$  des moindres carrés de  $\lambda$  défini par

$$\hat{\lambda} = \arg \min_{\lambda \in \mathbb{R}^{p+1}} \|\mathbf{Y} - V\lambda\|^2$$

est donné par

$$\hat{\lambda} := \begin{bmatrix} C^{-1} A^T \mathbf{Y} \\ \|\mathbf{z}_\perp\|^{-2} \mathbf{z}_\perp^T \mathbf{Y} \end{bmatrix}.$$

3. Déterminer l'estimateur  $(\hat{\beta}, \hat{\gamma})$  des moindres carrés de  $(\bar{\beta}, \gamma)$ , défini par

$$(\hat{\beta}, \hat{\gamma}) = \arg \min_{(\bar{\beta}, \gamma) \in \mathbb{R}^p \times \mathbb{R}} \|\mathbf{Y} - A\bar{\beta} - \mathbf{z}\gamma\|^2$$

en fonction de  $\hat{\lambda}$ .

4. Déterminer la distribution de l'estimateur  $\hat{\gamma}$  sous  $\mathbb{Q}_{\bar{\theta}}$  pour  $\bar{\theta} = (\bar{\beta}, \gamma, \bar{\sigma}^2) \in \bar{\Theta}$ .  
 5. Montrer que le projecteur orthogonal  $\bar{H}$  sur  $\text{Im}(V)$  est donné par

$$\bar{H} := H + \|\mathbf{z}_\perp\|^{-2} \mathbf{z}_\perp \mathbf{z}_\perp^T.$$

6. En déduire un estimateur  $\hat{\sigma}^2$  sans biais de  $\bar{\sigma}^2$  [exprimer  $\hat{\sigma}^2$  en fonction de  $\hat{\sigma}^2$  et  $\mathbf{z}_\perp^T \mathbf{Y}$ ].  
 7. Déterminer la distribution de  $(n-p-1)\hat{\sigma}^2/\bar{\sigma}^2$  sous  $\mathbb{Q}_{\bar{\theta}}$  pour  $\bar{\theta} = (\bar{\beta}, \gamma, \bar{\sigma}^2) \in \bar{\Theta}$ .  
 8. Construire un test  $H_0 : \gamma = 0$ , contre  $H_1 : \gamma \neq 0$  de niveau  $\alpha \in ]0, 1[$ .

**Exercice 2.** Soit  $n \geq 3$  et  $Z = (X_1, \dots, X_n)$  un  $n$ -échantillon du modèle

$$(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+), \{p_\theta \cdot \text{Leb}, \theta \in \mathbb{R}_+^*\}),$$

où  $\text{Leb}$  est la mesure de Lebesgue sur  $\mathbb{R}$  et  $p_\theta$  est définie par

$$x \mapsto p_\theta(x) := \theta x^{\theta-1} \mathbb{1}_{]0,1[}(x) = \theta e^{(\theta-1)\log(x)} \mathbb{1}_{]0,1[}(x).$$

Nous admettons que le modèle statistique est régulier.

1. Déterminer l'estimateur du maximum de vraisemblance  $\hat{\theta}_n$  du paramètre  $\theta$ .
2. Déterminer la distribution asymptotique de la suite d'estimateurs  $\sqrt{n}(\hat{\theta}_n - \theta)$ .
3. Montrer que sous  $p_\theta \cdot \text{Leb}$ , la loi de la variable  $Y_1 := -\log(X_1)$  est  $\text{Gamma}(1, \theta)$  (voir Définition IV-5.12 dans le polycopié). En déduire la loi, sous  $p_\theta \cdot \mu$ , de  $\sum_{i=1}^n Y_i$  où  $Y_i := -\log(X_i)$ .
4. Calculer pour tout  $\theta \in \mathbb{R}_+^*$ ,  $\mathbb{E}_\theta[\hat{\theta}_n]$  et  $\text{Var}_\theta(\hat{\theta}_n)$ .
5. Montrer qu'il existe une suite réelle (déterministe)  $\{a_n, n \in \mathbb{N}\}$  telle que  $\tilde{\theta}_n := a_n \hat{\theta}_n$  soit un estimateur sans biais de  $\theta$ .
6. L'estimateur  $\tilde{\theta}_n$  est-il efficace ?
7. Montrer que  $n\theta/\hat{\theta}_n$  est une fonction pivotale pour le paramètre  $\theta$  dont on déterminera la distribution. En déduire un intervalle de confiance exact de niveau  $1 - \alpha$  pour  $\alpha \in ]0, 1[$ .

**Exercice 3.** Soit  $Z = (X_1, \dots, X_n)$  un  $n$ -échantillon du modèle

$$(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+), \{p_\theta \cdot \text{Leb}, \theta = (\mu, \rho) \in \Theta := \mathbb{R} \times \mathbb{R}_+^*\}),$$

où  $\text{Leb}$  est la mesure de Lebesgue sur  $\mathbb{R}$  et  $p_\theta$  est définie par

$$x \mapsto p_\theta(x) := \frac{1}{\rho} \mathbb{1}_{[\mu-\rho/2, \mu+\rho/2]}(x), \quad \theta = (\mu, \rho) \in \Theta.$$

Dans la suite nous supposons que  $n \geq 3$ . Nous notons  $X_{n:1} := \min(X_1, \dots, X_n)$ ,  $X_{n:n} := \max(X_1, \dots, X_n)$  et  $R_n := X_{n:n} - X_{n:1}$  et pour  $\theta = (\mu, \rho) \in \Theta$ ,

$$A_\theta := \{(u, v) \in \mathbb{R}^2 : \mu - \rho/2 \leq u \leq v \leq \mu + \rho/2\}.$$

1. Déterminer un estimateur de maximum de vraisemblance de  $(\mu, \rho)$ . Cet estimateur est-il unique ?
2. Soit  $\theta = (\mu, \rho) \in \Theta$ . Montrer que sous  $\mathbb{P}_{n,\theta}$ , la loi jointe de  $(X_{n:1}, X_{n:n})$  a une densité par rapport à la mesure de Lebesgue sur  $\mathbb{R}^2$  donnée par

$$(u, v) \mapsto f_{n,\theta}(u, v) := \frac{n(n-1)}{\rho^n} (v-u)^{n-2} \mathbb{1}_{A_\theta}(u, v).$$

3. Soit  $\theta = (\mu, \rho) \in \Theta$ . Montrer que sous  $\mathbb{P}_{n,\theta}$ , la loi de  $R_n$  a une densité par rapport à la mesure de Lebesgue sur  $\mathbb{R}$  donnée par

$$r \mapsto g_{n,\theta}(r) := \frac{n(n-1)}{\rho^n} r^{n-2} (\rho-r) \mathbb{1}_{[0,\rho]}(r).$$

4. Soit  $\theta = (\mu, \rho) \in \Theta$ . Montrer que la suite  $n(\rho - R_n)$  converge en loi sous  $\mathbb{P}_{n,\theta}$  et identifier la loi limite.

**Exercice 4.** Dans la suite, toutes les variables sont définies sur le même espace de probabilité  $(\Omega, \mathcal{F}, \mathbb{P})$ .

On considère un problème de classification binaire. Nous étudions la situation où les données d'apprentissage sont affectées d'erreurs sur les labels. Pour formaliser cette situation, nous supposons disposer d'un ensemble d'apprentissage  $\{(X_i, Z_i)\}_{i=1}^n$ , où  $n$  est le nombre d'exemples,  $\{(X_i, Z_i)\}_{i=1}^n$  est une suite de variables aléatoires i.i.d. de même loi que  $(X, Z)$ . Nous notons  $(X, Y)$  le couple "attribut" "label", avec  $Y \in \{0, 1\}$  et notons  $Z$ , le label bruité

$$Z := \begin{cases} Y & \text{si } B = 0, \\ 1 - Y & \text{si } B = 1, \end{cases}$$

où  $B$  est une variable de Bernoulli de paramètre  $p \in [0, 1/2[$  indépendante de  $(X, Y)$ .

Nous notons  $\mathcal{C}$  un ensemble de règles de classification que nous supposons de cardinal  $|\mathcal{C}|$  fini. Pour tout  $g \in \mathcal{C}$ , nous définissons

- le risque de classification sur les observations sans bruit :  $R(g) := \mathbb{P}(g(X) \neq Y)$ ,
- le risque de classification sur les observations bruitées :  $R^b(g) := \mathbb{P}(g(X) \neq Z)$ ,
- le risque empirique sur les observations bruitées :  $R_n^b(g) := \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{g(X_i) \neq Z_i\}}$ .
- $g^*$  une règle de classification minimisant le risque de classification sans bruit :  $g^* \in \arg \min_{g \in \mathcal{C}} R(g)$

- $\hat{g}_n^*$  une règle de classification minimisant le risque empirique sur les observations bruitées :  
 $\hat{g}_n^* \in \arg \min_{g \in \mathcal{C}} R_n^b(g)$
- $R^*$  le minimum du risque de classification :  $R^* := \inf_{g \in \mathcal{C}} R(g) = R(g^*)$ .

Soit  $\varepsilon > 0$  et  $\delta \in ]0, 1[$ , fixés dans toute la suite. Nous allons démontrer que la suite de règles de classification  $\hat{g}_n^*$  est  $(\varepsilon, \delta)$ -PAC, i.e. il existe un entier  $n(\varepsilon, \delta)$  (que nous déterminerons) tel que

$$\forall n \geq n(\varepsilon, \delta), \quad \mathbb{P}(R(\hat{g}_n^*) - R^* > \varepsilon) \leq \delta. \quad (1)$$

Posons  $\bar{\varepsilon} := \varepsilon(1 - 2p)$ .

1. Montrer que pour tout  $g \in \mathcal{C}$ ,

$$R^b(g) = p + R(g)(1 - 2p).$$

En déduire une relation entre  $R^b(g) - R^b(g^*)$  et  $R(g) - R(g^*)$  pour tout classifieur  $g \in \mathcal{C}$ .

2. Montrer qu'il existe  $n_0(\varepsilon, \delta)$  (que l'on déterminera) tel que pour tout  $n \geq n_0(\varepsilon, \delta)$ ,

$$\mathbb{P}\left(R_n^b(g^*) - R^b(g^*) \leq \bar{\varepsilon}/2\right) \geq 1 - \delta/2.$$

3. Montrer qu'il existe  $n_1(\varepsilon, \delta)$  (que l'on déterminera) tel que pour tout  $n \geq n_1(\varepsilon, \delta)$ ,

$$\mathbb{P}\left(\sup_{g \in \mathcal{C}} \{R^b(g) - R_n^b(g)\} \leq \bar{\varepsilon}/2\right) \geq 1 - \delta/2.$$

4. Etablir 1 [déterminer  $n(\varepsilon, \delta)$ ].
5. De combien doit augmenter le nombre de données pour avoir la même garantie entre  $p = 0$  et  $p = 0,05$  ?