

Par convention, les vecteurs sont des vecteurs colonne. Pour un vecteur ou une matrice x , x^\top désigne la transposée de x . \mathbf{I}_n est la matrice identité de taille $n \times n$.

L'espérance et la variance d'une loi géométrique sur \mathbb{N} de paramètre θ , $\theta \in]0, 1[$, sont : $(1 - \theta)/\theta$ et $(1 - \theta)/\theta^2$.

Sujet

Exercice 1. On cherche à expliquer une variable quantitative Y_i (réponse) par un vecteur de régresseurs \mathbf{z}_i , $i \in \{1, \dots, n\}$. On pose $\theta := (\boldsymbol{\beta}, \sigma^2) \in \Theta := \mathbb{R}^p \times \mathbb{R}_+^*$. Le *modèle linéaire* consiste à supposer que, pour tout $\theta \in \Theta$, les variables

$$\varepsilon_i(\theta) := \sigma^{-1} \left\{ Y_i - \mathbf{z}_i^\top \boldsymbol{\beta} \right\}, \quad i = 1, 2, \dots, n,$$

sont des variables indépendantes et identiquement distribuées. Nous utilisons les notations matricielles / vectorielles :

$$\mathbf{Y} = \mathbf{Z}\boldsymbol{\beta} + \sigma\boldsymbol{\varepsilon}(\theta), \quad (1)$$

où

$$\mathbf{Y} := \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}, \quad \boldsymbol{\varepsilon}(\theta) := \begin{bmatrix} \varepsilon_1(\theta) \\ \vdots \\ \varepsilon_n(\theta) \end{bmatrix}, \quad \mathbf{Z} := \begin{bmatrix} \mathbf{z}_1^\top \\ \mathbf{z}_2^\top \\ \vdots \\ \mathbf{z}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p};$$

\mathbf{Y} est le vecteur des observations, $\boldsymbol{\beta}$ est le vecteur des paramètres de régression et \mathbf{Z} est la matrice de régression de taille $n \times p$. Nous supposons que $n > p + 1$.

Pour $i \in \{1, \dots, n\}$, nous notons $\mathbf{Z}_{[i]}$ et $\mathbf{Y}_{[i]}$ la matrice \mathbf{Z} et le vecteur \mathbf{Y} dont la i -ème ligne a été retirée. Nous supposons que

GM1 pour tout $i \in \{1, \dots, n\}$, la matrice $\mathbf{Z}_{[i]}$ est de rang p .

GM2 les erreurs de régression sont *homoscédastiques* : pour tout $\theta \in \Theta$, $\mathbb{E}_\theta[\boldsymbol{\varepsilon}(\theta)] = \mathbf{0}$ et $\text{Cov}_\theta(\boldsymbol{\varepsilon}(\theta)) = \mathbf{I}_n$.

L'hypothèse GM1 implique que la matrice de Gram $\mathbf{Z}^\top \mathbf{Z}$ est inversible et l'hypothèse GM2 entraîne que pour tout $\theta \in \Theta$

$$\mathbb{E}_\theta[\mathbf{Y}] = \mathbf{Z}\boldsymbol{\beta}, \quad \text{Cov}_\theta(\mathbf{Y}) = \sigma^2 \mathbf{I}_n.$$

Nous notons par $\hat{\boldsymbol{\beta}}$ l'estimateur des moindres carrés basé sur (\mathbf{Z}, \mathbf{Y}) et pour $i \in \{1, \dots, n\}$, par $\hat{\boldsymbol{\beta}}_{[i]}$ l'estimateur des moindres carrés basé sur $(\mathbf{Z}_{[i]}, \mathbf{Y}_{[i]})$:

$$\hat{\boldsymbol{\beta}} := (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y} = \mathbf{Z}^\# \mathbf{Y}, \quad \hat{\boldsymbol{\beta}}_{[i]} := (\mathbf{Z}_{[i]}^\top \mathbf{Z}_{[i]})^{-1} \mathbf{Z}_{[i]}^\top \mathbf{Y}_{[i]} = \mathbf{Z}_{[i]}^\# \mathbf{Y}_{[i]}. \quad (2)$$

Nous introduisons le résidu et le résidu prédictif, donnés respectivement par

$$\hat{e}_i := Y_i - \mathbf{z}_i^\top \hat{\boldsymbol{\beta}} \quad \hat{e}_{[i]} := Y_i - \mathbf{z}_i^\top \hat{\boldsymbol{\beta}}_{[i]}.$$

1. Montrer que pour tout $\theta \in \Theta$, $\mathbb{E}_\theta[\hat{\boldsymbol{\beta}}_{[i]}] = \boldsymbol{\beta}$ et $\text{Cov}_\theta(\hat{\boldsymbol{\beta}}_{[i]}) = \sigma^2 (\mathbf{Z}_{[i]}^\top \mathbf{Z}_{[i]})^{-1}$.
2. Montrer que pour tout $\theta \in \Theta$, $\mathbb{E}_\theta[\hat{e}_{[i]}] = 0$ et $\text{Var}_\theta(\hat{e}_{[i]}) = \sigma^2 + \sigma^2 \mathbf{z}_i^\top (\mathbf{Z}_{[i]}^\top \mathbf{Z}_{[i]})^{-1} \mathbf{z}_i$.

On admettra que si A est une matrice $q \times q$ inversible, et $\mathbf{u} \in \mathbb{R}^q$,

$$\begin{aligned} (A + \mathbf{u}\mathbf{u}^\top)^{-1} &= A^{-1} - \frac{A^{-1}\mathbf{u}\mathbf{u}^\top A^{-1}}{1 + \mathbf{u}^\top A^{-1}\mathbf{u}}, \\ (A - \mathbf{u}\mathbf{u}^\top)^{-1} &= A^{-1} + \frac{A^{-1}\mathbf{u}\mathbf{u}^\top A^{-1}}{1 - \mathbf{u}^\top A^{-1}\mathbf{u}}, \quad \text{si } \mathbf{u}^\top A^{-1}\mathbf{u} \neq 1. \end{aligned}$$

Nous posons, pour $i \in \{1, \dots, n\}$, $m_{ii} := \mathbf{z}_i^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{z}_i$.

3. Montrer que $0 \leq m_{ii} < 1$ pour tout $i = 1, \dots, n$.

4. Montrer que pour tout $i = 1, \dots, n$,

$$\left(\mathbf{Z}_{[i]}^\top \mathbf{Z}_{[i]} \right)^{-1} = \left(\mathbf{Z}^\top \mathbf{Z} \right)^{-1} + \frac{1}{1 - m_{ii}} \left(\mathbf{Z}^\top \mathbf{Z} \right)^{-1} \mathbf{z}_i \mathbf{z}_i^\top \left(\mathbf{Z}^\top \mathbf{Z} \right)^{-1}.$$

5. En déduire que pour tout $i = 1, \dots, n$,

$$\hat{\boldsymbol{\beta}}_{[i]} = \hat{\boldsymbol{\beta}} - \frac{\hat{e}_i}{1 - m_{ii}} \left(\mathbf{Z}^\top \mathbf{Z} \right)^{-1} \mathbf{z}_i.$$

6. Montrer que pour tout $i = 1, \dots, n$: $\hat{e}_{[i]} = \hat{e}_i / (1 - m_{ii})$ et $\text{Var}_\theta(\hat{e}_{[i]}) = \sigma^2 / (1 - m_{ii})$.

On suppose maintenant que \mathbf{Y} est l'observation canonique d'un modèle gaussien

$$(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \{N_n(\mathbf{Z}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n) : \boldsymbol{\theta} = (\boldsymbol{\beta}, \sigma^2) \in \mathbb{R}^p \times \mathbb{R}_+^*\}).$$

Nous notons $\mathbf{H}_{[i]} := \mathbf{Z}_{[i]} \mathbf{Z}_{[i]}^\#$ et $\hat{\sigma}_{[i]}^2 := (n - p - 1)^{-1} \|(\mathbf{I}_{n-1} - \mathbf{H}_{[i]})\mathbf{Y}_{[i]}\|^2$.

7. Sous \mathbb{P}_θ , montrer que $\hat{e}_{[i]} = Y_i - \mathbf{z}_i^\top \hat{\boldsymbol{\beta}}_{[i]}$ est distribué suivant une loi Gaussienne dont on précisera les paramètres en fonction de σ^2 et m_{ii} .

8. Sous \mathbb{P}_θ , montrer que $(n - p - 1)\hat{\sigma}_{[i]}^2/\sigma^2$ est distribué suivant une loi de χ^2 à $(n - p - 1)$ degrés de liberté, et est indépendant de $\hat{\boldsymbol{\beta}}_{[i]}$ et Y_i .

9. En déduire la distribution sous \mathbb{P}_θ du résidu standardisé

$$t_i := \frac{\hat{e}_{[i]}}{\sqrt{\hat{\sigma}_{[i]}^2/(1 - m_{ii})}}.$$

10. Proposer une méthode pour détecter une valeur aberrante dans les observations.

Exercice 2. Soit $\{(X_1, Y_1), \dots, (X_n, Y_n)\}$ une suite de n -échantillons du modèle statistique

$$(\mathbb{R}_+^2, \mathcal{B}(\mathbb{R}_+^2), \{p_\theta \cdot \text{Leb}^{\otimes 2}, \theta = (\theta_1, \theta_2) \in \Theta := \mathbb{R}_+^* \times \mathbb{R}_+^*\})$$

où

$$p_\theta : (x, y) \in \mathbb{R}_+^2 \mapsto \theta_1^{-1} \exp(-x/\theta_1) \theta_2^{-1} \exp(-y/\theta_2).$$

On s'intéresse dans cet exercice à l'estimation de $g(\theta)$, où la fonction g est définie par $g : \Theta \rightarrow \mathbb{R}_+$, $\theta \mapsto \mathbb{P}_\theta(X_1 \leq Y_1)$. On admettra que le modèle statistique est régulier. On rappelle que $\mathbb{E}_\theta[X_1] = \theta_1$, $\text{Var}_\theta(X_1) = \theta_1^2$.

On considère d'abord l'estimateur

$$T_n = n^{-1} \sum_{i=1}^n \mathbb{1}_{\{X_i \leq Y_i\}}.$$

1. Montrer que, pour tout $\theta \in \Theta$, $g(\theta) = \theta_2/(\theta_1 + \theta_2)$.
2. Montrer que (T_n) est une suite d'estimateurs de $g(\theta)$ asymptotiquement normale. Déterminer sa variance asymptotique.

On note $\hat{\theta}_n^{\text{MV}}$ l'estimateur du maximum de vraisemblance de θ et on considère $\tilde{T}_n = g(\hat{\theta}_n^{\text{MV}})$ comme second estimateur de $g(\theta)$.

3. Montrer que $\hat{\theta}_n^{\text{MV}}$ est une suite d'estimateurs de θ asymptotiquement normale et déterminer sa covariance asymptotique.
4. Montrer que (\tilde{T}_n) est une suite d'estimateurs de $g(\theta)$ asymptotiquement normale et déterminer sa variance asymptotique.
5. Quel estimateur de $g(\theta)$ doit-on choisir ?
6. Construire un intervalle de confiance asymptotique de $g(\theta)$ de probabilité de couverture $1 - \alpha$, pour $\alpha \in]0, 1[$.
7. Construire une suite de tests de niveau asymptotique α de l'hypothèse $H_0 : g(\theta) \leq 1/2$, contre $H_1 : g(\theta) < 1/2$.

Exercice 3. La probabilité $\theta \in]0, 1[$ d'un événement est généralement estimée en examinant la fréquence à laquelle il se produit (on parle de "succès") au cours de n essais indépendants. Une autre façon d'estimer θ est de déterminer le nombre d'échecs Y_r pour obtenir $r \geq 2$ succès.

Soit $\{X_k\}_{k \in \mathbb{N}}$ une suite de variables aléatoires indépendantes distribuées suivant une loi de Bernoulli de paramètre $\theta \in \Theta :=]0, 1[$. Nous notons pour $r \in \mathbb{N}^*$, $Z_r := Y_r - Y_{r-1}$, le nombre d'échecs entre le $(r-1)$ -ème et le r -ème succès, où par convention nous posons $Y_0 := 0$.

1. Montrer que sous \mathbb{P}_θ , les statistiques $\{Z_1, \dots, Z_r\}$ sont indépendantes et identiquement distribuées de loi géométrique sur \mathbb{N} de paramètre θ .
2. Déterminer le modèle statistique induit par les statistiques Z_1, \dots, Z_r .
3. Justifier soigneusement que, sous \mathbb{P}_θ , la loi de Y_r est donnée par

$$\mathbb{P}_\theta(Y_r = y) = \binom{y+r-1}{r-1} \theta^r (1-\theta)^y, \quad y \in \mathbb{N}.$$

4. Déterminer l'estimateur du maximum de vraisemblance $\hat{\theta}_r$ du paramètre θ sous le modèle induit par Z_1, \dots, Z_r .
5. Montrer que $\hat{\theta}_r$ coïncide avec l'estimateur du maximum de vraisemblance sous le modèle induit par Y_r .
6. Montrer que la suite d'estimateurs $\{\hat{\theta}_r\}_{r=1}^\infty$ est asymptotiquement normale. Préciser la variance asymptotique.
7. Montrer que l'estimateur

$$\tilde{\theta}_r := \frac{r-1}{Y_r + r - 1}$$

est un estimateur sans biais du paramètre θ .

8. Montrer $\tilde{\theta}_r$ est l'unique estimateur sans biais sous le modèle induit par Y_r .

Soit $T(Z_1, \dots, Z_r)$ un estimateur sans biais de θ basé sur Z_1, \dots, Z_r .

9. Montrer qu'il existe une fonction $\tilde{T}(Y_r)$ telle que, pour tout $\theta \in \Theta$, $\mathbb{E}_\theta [T(Z_1, \dots, Z_r) | Y_r] = \tilde{T}(Y_r)$.
10. Montrer que $\tilde{T}(Y_r)$ est un estimateur sans biais de θ .
11. Montrer que pour tout $\theta \in \Theta$,

$$\mathbb{E}_\theta [(T(Z_1, \dots, Z_r) - \theta)^2] = \mathbb{E}_\theta [(T(Z_1, \dots, Z_r) - \tilde{T}(Y_r))^2] + \mathbb{E}_\theta [(\tilde{T}(Y_r) - \theta)^2]$$
12. En déduire que $\tilde{\theta}_r$ est aussi l'estimateur sans biais de variance minimale dans le modèle induit par Z_1, \dots, Z_r .

Exercice 4. Nous considérons un problème de classification binaire. Nous supposons que l'observation (X, Y) (où $X \in \mathbf{X} \subseteq \mathbb{R}^d$ est le vecteur des attributs, et $Y \in \{-1, 1\}$ est l'étiquette) est un vecteur aléatoire défini sur un espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$ à valeurs dans $\mathbb{R}^d \times \{-1, 1\}$. Nous notons

$$\eta(X) := \mathbb{E} [\mathbb{1}_{\{Y=1\}} | X] ,$$

et nous supposons que $\eta(X)$ est à valeurs dans $]0, 1[$ avec probabilité 1.

Pour une règle de décision $g : \mathbf{X} \rightarrow \mathbb{R}$, nous nous intéressons à la fonction de risque exponentiel

$$R_e(g) := \mathbb{E} [\exp(-Yg(X))] . \quad (3)$$

Rappelons que g est une règle de décision "douce". Nous déciderons 1 si $\text{signe}(g(x)) \geq 0$ et -1 sinon. Nous posons pour $(\eta, p) \in]0, 1[\times \mathbb{R}$,

$$C_e(\eta, p) := \eta \exp(-p) + (1 - \eta) \exp(p) .$$

1. Montrer que

$$R_e(g) = \mathbb{E} [C_e(\eta(X), g(X))] .$$

2. Montrer que pour tout $\eta \in]0, 1[$, $p \mapsto C_e(\eta, p)$ admet un minimum unique ; on le notera $p_e(\eta)$.

On pose pour tout $x \in \mathbf{X}$,

$$g_e(x) := p_e(\eta(x)) .$$

3. En déduire que g_e est le classifieur bayésien pour le risque exponentiel (3).

On pose $R_e^* := R_e(g_e)$. Pour tout $\eta \in]0, 1[$, on définit

$$H_e(\eta) := C_e(\eta, p_e(\eta)) = \inf_{p \in \mathbb{R}} C_e(\eta, p) .$$

4. Montrer que

$$H_e(\eta) = 2\sqrt{\eta(1-\eta)} \quad \text{pour } \eta \in]0, 1[.$$

Nous notons R_{0-1} le risque 0-1 : pour toute fonction $g : \mathbf{X} \rightarrow \mathbb{R}$,

$$R_{0-1}(g) := \mathbb{E} [\mathbb{1}_{\{\text{signe}(g(X)) \neq Y\}}] .$$

On a toujours, pour toute fonction $g : \mathbf{X} \rightarrow \mathbb{R}$, $R_{0-1}(g) = R_{0-1}(\text{signe}(g))$. Soit

$$g_{0-1}^*(x) := \text{signe}(2\eta(x) - 1) , \quad x \in \mathbf{X} .$$

On rappelle que g_{0-1}^* minimise le risque R_{0-1} . On pose

$$R_{0-1}^* := R_{0-1}(g_{0-1}^*) .$$

5. Montrer que $\text{signe}(g_e)$ est une règle de décision Bayésienne pour le risque 0-1.
 6. Montrer que pour tout classifieur g

$$R_{0-1}(g) - R_{0-1}^* = \mathbb{E}[|2\eta(X) - 1| \mathbb{1}_{\{g(X) (2\eta(X)-1) \leq 0\}}].$$

7. En déduire que si ψ est convexe sur $[0, 1]$ et $\psi(0) = 0$:

$$\psi(R_{0-1}(g) - R_{0-1}^*) \leq \mathbb{E}[\psi(|2\eta(X) - 1|) \mathbb{1}_{\{g(X) (2\eta(X)-1) \leq 0\}}]$$

8. Montrer que, pour tout $\eta \in]0, 1[$,

$$\inf_{p \in \mathbb{R} : p(2\eta-1) \leq 0} C_e(\eta, p) = 1.$$

On définit la fonction H_e^- sur $]0, 1[$ et la fonction ψ_e sur $[0, 1[$, par

$$H_e^-(\eta) := \inf_{p \in \mathbb{R} : p(2\eta-1) \leq 0} C_e(\eta, p), \quad \eta \in]0, 1[,$$

$$\psi_e(\theta) := H_e^-\left(\frac{1+\theta}{2}\right) - H_e\left(\frac{1+\theta}{2}\right) = 1 - H_e\left(\frac{1+\theta}{2}\right), \quad \theta \in [0, 1[.$$

9. Montrer que pour tout $\eta \in]0, 1[$, $H_e(\eta) = H_e(1 - \eta)$ et

$$\psi_e(|2\eta - 1|) = 1 - H_e(\eta) = H_e^-(\eta) - H_e(\eta).$$

10. Montrer que $\psi_e(0) = 0$ et que ψ_e est convexe sur $[0, 1[$.
 11. En déduire que, pour tout classifieur g , nous avons

$$\psi_e(R_{0-1}(g) - R_{0-1}^*) \leq R_e(g) - R_e^*.$$